

Mortalidad por cáncer en los condados de Estados Unidos

Un modelo de regresión lineal múltiple

Proyecto final: *Multiple Linear Regression Challenge*

Lic. Richard Alejandro Matos Arderí

Lic. Abel Ponce González

Lic. Lidier Robayna

Corrida analizada: 20261009-095405-f8341612 · commit aa76b3794edd

Fichero de datos: practica.sav (SHA-256 1924e0da423a7408...)

Resumen

Se estudia qué características socioeconómicas, demográficas y sanitarias de los condados de Estados Unidos se asocian con su tasa de mortalidad por cáncer (muertes anuales por 100 000 habitantes), a partir del fichero oficial `practica.sav` (3047 condados), que se comprueba celda a celda que coincide con el conjunto público del que procede (Rippner 2017). Un catálogo de 19 reglas de validación detecta valores centinela, edades registradas en meses, tamaños de hogar divididos por cien y una variable que filtra la respuesta; once decisiones documentadas los resuelven y, tras la depuración, ninguna regla queda en estado de error.

El modelo final se estima por mínimos cuadrados ordinarios (MCO), como pide la orientación, con 2840 condados y 19 regresores: 10 términos elegidos por eliminación hacia atrás con contrastes robustos, 1 variable reincorporada por confusión y 2 interacciones con la región censal. Explica el 55,8 % de la variabilidad ($R^2 = 0,558$, $\bar{R}^2 = 0,555$) con un error cuadrático medio de 18,44 muertes por 100 000 habitantes dentro de la muestra. Como los errores son heterocedásticos (su varianza decrece con la población del condado) y dependen dentro de cada estado (correlación intraclase 0,079), la inferencia usa errores típicos robustos por conglomerados de estado; los clásicos se presentan como salida tipo SPSS y una sintaxis generada automáticamente reproduce el modelo en ese programa.

A igualdad del resto de variables, la mortalidad crece con la incidencia de cáncer y con la proporción de residentes que sólo tienen cobertura pública, y decrece con el porcentaje de adultos con título universitario, con un gradiente educativo que es menor en el Noreste. Las conclusiones se mantienen en las 10 especificaciones del análisis de sensibilidad y en el bootstrap por conglomerados (ponderación por la función de varianza, efectos fijos de estado, modelo mixto, regresión robusta, exclusión de observaciones influyentes e imputación múltiple, entre otras). Como complemento, un modelo predictivo (ridge) alcanza un RMSE de 17,36 en una partición de prueba no usada para ajustar ni elegir.

Palabras clave: regresión lineal múltiple, mínimos cuadrados ordinarios, errores típicos robustos por conglomerados, diagnóstico de hipótesis, datos ausentes, mortalidad por cáncer.

Índice general

Resumen	I
1. Introducción	1
1.1. Pregunta y alcance	1
1.2. Correspondencia con los entregables	1
1.3. Cómo está hecho este informe	1
2. Datos, validación y depuración	3
2.1. Fuente y procedencia	3
2.2. Variables que no pueden ser explicativas	3
2.3. Validación	3
2.4. Depuración: once decisiones documentadas	4
2.5. Variables categóricas	5
3. Datos ausentes y valores atípicos	7
3.1. Cuánto falta y dónde	7
3.2. Mecanismo de la ausencia	7
3.3. Valores atípicos	8
4. Análisis exploratorio e inferencia clásica	9
4.1. La respuesta: mortalidad por cáncer	9
4.1.1. Normalidad	9
4.1.2. Independencia en el orden del fichero	10
4.2. Diferencias entre regiones	10
4.3. Dos contrastes de dos muestras	12
4.4. Asociaciones marginales	12
5. Construcción del modelo	14
5.1. Especificación de partida	14
5.2. Colinealidad	14
5.3. Estructura del error y estrategia de inferencia	15
5.4. Selección de variables	16
5.5. Confusión	17
5.6. Interacciones	17
5.7. Comparación de modelos anidados	18
6. El modelo final	19

6.1. Especificación y coeficientes	19
6.2. Salida tipo SPSS: R^2 , R^2 ajustado y RMSE	20
6.2.1. Errores típicos clásicos, HC3 y por conglomerados	21
6.3. Interpretación	22
6.3.1. La constante y las regiones	22
6.3.2. Efectos principales	22
6.3.3. Interacciones: efectos que dependen de la región	23
6.3.4. ¿Qué cambia si no se ajusta por la incidencia?	24
7. Diagnóstico del modelo	26
7.1. Linealidad	26
7.2. Independencia de los errores	28
7.3. Homocedasticidad	29
7.4. Normalidad de los residuos	29
7.5. Multicolinealidad	29
7.6. Media de los residuos	29
7.7. Observaciones atípicas e influyentes	29
8. Análisis de sensibilidad	31
8.1. ¿Habría que transformar la respuesta?	33
9. Modelo predictivo	34
9.1. Protocolo	34
9.2. Resultados	34
9.3. Importancia de las variables	36
9.4. Intervalos de predicción conformales	36
10. Conclusiones	37
10.1. Respuesta a la pregunta	37
10.2. Limitaciones	37
10.3. Trabajo futuro	37
A. Código y reproducibilidad	39
A.1. Estructura	39
A.2. Cómo reproducir el análisis	39
A.3. Sintaxis de SPSS	40
B. Tablas complementarias	43
Bibliografía	45

Introducción

1.1 Pregunta y alcance

La mortalidad por cáncer varía mucho entre los condados de Estados Unidos: en el fichero analizado va de 59,7 muertes por 100 000 habitantes (Pitkin County, Colorado) a 362,8 (Union County, Florida). El objetivo del trabajo, fijado por la orientación del proyecto, es construir un modelo de regresión lineal múltiple estimado por mínimos cuadrados ordinarios que explique y prediga esa tasa (TARGET_deathRate) a partir de las demás características del condado, y acompañarlo de su diagnóstico completo.

Se distinguen dos usos del modelo, que requieren criterios distintos:

- **Modelo de efectos** (capítulos 5 a 8): estimar e interpretar la asociación de cada característica con la mortalidad, ajustada por las demás, con una inferencia válida (intervalos y contrastes con la cobertura y el nivel nominales).
- **Modelo predictivo** (capítulo 9): acertar en condados nuevos, evaluado con validación cruzada y una partición de prueba independiente.

Los datos son *ecológicos*: cada observación es un condado, no una persona. Las asociaciones estimadas describen condados y no deben trasladarse a individuos (falacia ecológica, Robinson 1950). Además, el diseño es observacional, por lo que los coeficientes son asociaciones condicionales, no efectos causales.

1.2 Correspondencia con los entregables

La orientación pide seis entregables. La tabla 1.1 indica dónde se responde cada uno.

Tabla 1.1: Entregables de la orientación y su localización en el informe

Entregable	Dónde
(a) Modelo final y pasos seguidos para construirlo	capítulos 5 y 6
(b) Salida del software con R^2 , R^2 ajustado y RMSE	apartado 6.2
(c) Código	apéndice A
(d) Diagnóstico: linealidad, independencia, homocedasticidad, normalidad, multicolinealidad	capítulo 7
(e) Interpretación del modelo	apartado 6.3
(f) Atípicos, valores perdidos y variables categóricas	capítulos 2 y 3

1.3 Cómo está hecho este informe

Todo el análisis se ejecuta con un paquete de Python propio (cancerstats) a partir de una configuración declarativa: cada decisión metodológica (umbral, estimador, estrategia de selección, interacciones candidatas...) es una opción con su justificación. Cada ejecución queda registrada como

una *corrida* con su configuración, el entorno de software, la huella del código y de los datos, el registro y todos los resultados. Las cifras, tablas y figuras de este documento se generan automáticamente a partir de la última corrida (20261009-095405-f8341612, del 2026-10-09 09:56:44 UTC); ninguna se ha copiado a mano. El apéndice A describe cómo reproducirlo, la interfaz interactiva y la sintaxis de SPSS equivalente.

La referencia teórica es Wasserman (2004), texto del curso, complementado con Fox (2016) y Wooldridge (2010) para el diagnóstico y la inferencia robusta.

Datos, validación y depuración

2.1 Fuente y procedencia

El profesor entregó el fichero `practica.sav` (SPSS), con 3047 condados y 35 columnas; su huella SHA-256 empieza por 1924e0da423a7408, lo que identifica sin ambigüedad el fichero analizado. Procede del conjunto público *OLS Regression Challenge* (Rippner 2017), que agrega datos de la *American Community Survey*, de `clinicaltrials.gov` y de `cancer.gov`. Antes de reutilizar la documentación pública de las variables se comprobó, celda a celda y en el mismo orden de filas, que ambas fuentes contienen los mismos datos. Sólo hay dos diferencias, y las dos están explicadas:

- el fichero oficial ya trae como perdidos del sistema los casos anuales (`avgAnnCount`) de los condados cuyos registros no publican datos por condado, que el CSV público rellena con un valor centinela;
- el fichero oficial añade una variable sin documentar, `Notificadomuerte`, que resulta ser exactamente $\text{avgAnnCount} - \text{avgDeathsPerYear}$ en todos los condados en que ambas constan (regla R19).

La tabla B.1 (apéndice B) recoge el diccionario: etiqueta, unidad, tipo, fuente y papel de cada variable en el análisis.

2.2 Variables que no pueden ser explicativas

Algunas columnas se excluyen de los modelos por motivos de fondo, no por su significación (tabla B.2, apéndice B):

- **Fuga de información.** `avgDeathsPerYear` es el numerador de la tasa que se quiere explicar, y `Notificadomuerte` la contiene. Usarlas como explicativas daría un ajuste espectacular y vacío.
- **Escala.** `avgAnnCount` es un conteo que crece con la población; su versión por habitante es la incidencia, que sí se usa.
- **Redundancia exacta o casi exacta.** Las composiciones que suman 100 % (educación de 18–24 años, raza) obligan a omitir una categoría de referencia, igual que se omite una indicadora al codificar una variable cualitativa; las edades medianas por sexo repiten la edad mediana total ($r > 0,9$).

2.3 Validación

Se definió un catálogo de 19 reglas que comprueban el dominio de cada variable (porcentajes entre 0 y 100, tasas positivas), la coherencia entre variables (la edad mediana total entre la masculina y la femenina; empleo más desempleo no mayor que 100 %), las identidades contables (las cuatro categorías educativas de 18–24 años suman 100 %) y la plausibilidad (valores repetidos con muchos decimales, mortalidad mayor que incidencia). La tabla 2.1 muestra el resultado antes y después de depurar: en el fichero original fallan 4 reglas y 1 emite una advertencia; tras la depuración no queda ningún error (0).

Tabla 2.1: Catálogo de reglas de validación: casos que las incumplen antes y después de la depuración

Id.	Regla	Severidad	Original	Depurado
R01	Identificador único	error	0	0
R02	Porcentajes en [0, 100]	error	0	0
R03	Tasas, renta y población positivas	error	0	0
R04	Valores centinela	error	206	0
R05	Edad mediana plausible (≤ 100 años)	error	30	0
R06	Coherencia de las edades medianas	error	30	0
R07	Tamaño del hogar ≥ 1 persona	error	61	0
R08	Identidad educativa de 18–24 años	error	0	0
R09	Composición racial ≤ 100 %	error	0	0
R10	Empleo + desempleo ≤ 100 %	error	0	0
R11	Educación de 25+ años ≤ 100 %	error	0	0
R12	Jerarquía de coberturas sanitarias	error	0	0
R13	Renta mediana dentro de su decil	error	0	0
R14	Casos anuales $\geq$ muertes anuales	advert.	0	0
R15	Razón mortalidad/incidencia plausible	advert.	1	0
R16	Estado reconocido	error	0	0
R17	Ausentes declarados	info.	2504	872
R18	Inflación de ceros en ensayos clínicos	info.	1931	1931
R19	Identidad de Notificadomuerte	error	0	0

R17 y R18 son informativas: describen ausencias declaradas e inflación de ceros, que se tratan en etapas posteriores.

2.4 Depuración: once decisiones documentadas

Cada incidencia se trata con una decisión registrada (tabla 2.2) que expone el problema, la evidencia que lo prueba con los propios datos, la acción y su justificación. Las más relevantes son:

Valor centinela en la incidencia (D03).

La incidencia vale exactamente 453,549 422 1 en 206 condados, todos los de Kansas, Minnesota y Nevada. Una medición con siete decimales no se repite por azar cientos de veces: es una imputación previa por la media disfrazada de dato. Se marca como ausente; conservarla introduciría cientos de observaciones sin variación en la incidencia y sesgaría su coeficiente hacia cero.

Edad mediana en meses (D04).

30 condados declaran edades medianas de varios cientos de años. Divididas entre 12 quedan entre la mediana masculina y la femenina del mismo condado, lo que confirma el error de unidad; la razón media entre el valor erróneo y la media de las edades por sexo es 12,008 (desviación típica 0,067).

Tamaño del hogar dividido por cien (D05).

61 condados declaran menos de una persona por hogar; multiplicados por 100 quedan en el rango del resto.

Recuperación por identidad (D06).

Falta el 75,0 % de PctSomeCol18_24, pero las cuatro categorías educativas de 18–24 años suman 100 % (comprobado en los 762 condados completos, con un error máximo de 0,10 puntos por redondeo), así que el valor ausente se calcula sin error.

Variable derivada (D07).

En 86 condados las cuatro categorías raciales publicadas suman menos del 80 %: falta la población nativa americana y multirracial. Se construye como residuo, PctNativeMulti.

Incidencia inverosímil (D08).

En 1 condado (Aleutians West Census Area, Alaska) la mortalidad supera a la incidencia, cuando la razón mediana es 0,40; la incidencia de ese condado se marca como ausente.

Región censal (D09) y transformaciones (D10).

El estado tiene 51 categorías, algunas con uno o tres condados; se agrupa en las cuatro regiones de la Oficina del Censo. La población, la renta y los ensayos clínicos per cápita, muy asimétricos, se transforman con logaritmos.




Figura 2.1: Tres comprobaciones de la depuración: la edad mediana registrada en meses queda, al dividirla entre 12, entre las medianas por sexo; el tamaño del hogar dividido por 100; y la identidad educativa de 18–24 años que permite recuperar el dato ausente.

Tabla 2.2: Registro de decisiones de depuración

Id.	Decisión	Casos	Acción
D01	Geography separada en condado y estado	3047	Se separa por la última coma en Geography (condado) y state (estado).
D02	Notificadomuerte excluida por fuga de información	2841	Se conserva en los datos pero se excluye de todos los modelos.
D03	Valor centinela en la incidencia	206	Se sustituye por valor ausente.
D04	Edad mediana registrada en meses	30	Se divide entre 12 y se verifica que el resultado quede entre las medianas masculina y femenina.
D05	Tamaño medio del hogar dividido por 100	61	Se multiplica por 100.
D06	PctSomeCol18_24 recuperada por identidad contable	2285	Se calcula como 100 – (sin bachillerato + bachillerato + grado).
D07	Población nativa o multirracial (variable derivada)	86	Se crea PctNativeMulti = 100 – (blanca + negra + asiática + otra).
D08	Incidencia inverosímil (mortalidad $\geq$ incidencia)	1	Se marca la incidencia como ausente.
D09	Región censal	3047	Se agrupan en las cuatro regiones oficiales de la Oficina del Censo.
D10	Transformaciones de variables muy asimétricas	3047	Población: logaritmo; renta: logaritmo; ensayos: log1p.
D11	Variables excluidas de los modelos	12	Se excluyen: TARGET_deathRate, avgDeathsPerYear, avgAnnCount, Notificadomuerte, binnedInc, Geography, state, MedianAgeMale, MedianAgeFemale, PctPrivateCoverageAlone, PctSomeCol18_24, PctWhite.

2.5 Variables categóricas

El modelo incluye una explicativa cualitativa, la región censal (Sur, Noreste, Medio Oeste y Oeste), que se codifica con tres variables indicadoras y el Sur como categoría de referencia (la más numerosa:

1383 condados). Cada coeficiente de región es la diferencia esperada de mortalidad respecto del Sur a igualdad del resto de variables, y su significación conjunta se contrasta con un F de tres grados de libertad. El estado no se usa como explicativa en el modelo de efectos: con 51 categorías, varias casi vacías, consumiría 50 grados de libertad y absorbería toda la variación entre estados; en cambio, se tiene en cuenta en la estimación de los errores típicos (conglomerados) y como especificación de sensibilidad (efectos fijos de estado, capítulo 8). El decil de renta (`binnedInc`) es una versión agrupada de la renta mediana y se descarta en favor de la variable continua.

Datos ausentes y valores atípicos

3.1 Cuánto falta y dónde

Tras la depuración faltan datos en tres variables (tabla 3.1): la cobertura sólo privada (609 condados, 20,0 %), la incidencia (207, 6,8 %) y el empleo (152, 5,0 %). Sólo el 71,4 % de los condados (2175) está completo en todas las variables, pero la cobertura sólo privada no se usa como explicativa (es combinación casi lineal de las demás coberturas, apartado 5.2), de modo que el modelo pierde mucho menos.

Tabla 3.1: Datos ausentes tras la depuración y diagnóstico de su mecanismo

Variable	<i>n</i>	%	<i>p</i> (χ^2 estado)	Mecanismo
Solo seguro privado	609	20,0	0,052	compatible con MCAR
Incidencia de cáncer	207	6,8	< 0,001	Ausencia estructural
Empleo (16+)	152	5,0	0,591	compatible con MCAR

Contraste MCAR de Little sin la incidencia: $d^2 = 62,8$, 74 g.l., $p = 0,820$. Con la incidencia: $d^2 = 522,3$, 177 g.l., $p < 0,001$.

3.2 Mecanismo de la ausencia

El tratamiento adecuado depende del mecanismo (Rubin 1987): si la ausencia es completamente aleatoria (MCAR), analizar los casos completos no sesga, sólo resta precisión; si depende de variables observadas (MAR), los casos completos pueden sesgar y conviene imputar con esas variables; si depende del propio valor no observado (MNAR), ningún método lo resuelve sin supuestos externos. Se combinaron tres comprobaciones:

1. **Contraste de Little** (Little 1988). Estima por el algoritmo EM la media y la covarianza de todas las variables bajo normalidad y compara la media de cada patrón de ausencia con la estimada; bajo MCAR, el estadístico $d^2 = \sum_j n_j (\bar{y}_j - \hat{\mu}_j)^T \hat{\Sigma}_j^{-1} (\bar{y}_j - \hat{\mu}_j)$ sigue aproximadamente una χ^2 . Con las dos variables de ausencia dispersa no se rechaza MCAR ($d^2 = 62,8$, 74 g.l., $p = 0,820$); al añadir la incidencia se rechaza con claridad ($d^2 = 522,3$, 177 g.l., $p < 0,001$).
2. **Comparación de medias**. Para cada variable con ausentes, se compara la media de las demás entre condados con y sin el dato (Welch, corrección de Holm): ninguna diferencia es significativa para el empleo ni para la cobertura sólo privada.
3. **Asociación con el estado** (χ^2 de independencia entre la ausencia y el estado): la ausencia de la incidencia depende por completo del estado ($p < 0,001$); la del empleo no ($p = 0,591$).

La conclusión es que la incidencia falta por estados enteros (registros que no publican la cifra por condado): es una ausencia *estructural*, que no depende del valor no observado (no es MNAR) pero sí del estado, es decir, MAR dado el estado. Las otras dos ausencias son compatibles con MCAR.




Figura 3.1: Porcentaje de condados con el dato ausente en los catorce estados con más ausencias de incidencia: la de la incidencia afecta a estados completos (registros que no publican datos por condado); las del empleo y la cobertura sólo privada se reparten sin patrón.

Tratamiento elegido. El modelo de efectos usa los casos completos de sus variables. Como la ausencia de la incidencia es MAR, se comprueba que esa elección no altera las conclusiones con una imputación múltiple por ecuaciones encadenadas (van Buuren y Groothuis-Oudshoorn 2011), con extracciones de la distribución a posteriori de una regresión bayesiana: 20 conjuntos imputados que usan como auxiliares la respuesta, las demás explicativas y la región, combinados con las reglas de Rubin y los grados de libertad de Barnard y Rubin (1999) (capítulo 8). La imputación se evalúa sobre los 3047 condados.

3.3 Valores atípicos

Se buscaron atípicos en tres niveles. Un valor atípico *verificado como real* no se elimina: eliminarlo sesgaría las estimaciones y subestimaría la variabilidad; lo que importa es si una observación *influye* desproporcionadamente en el modelo, lo que se evalúa en el capítulo 7.

- **Univariantes.** Vallas de Tukey ($Q_1 - 1,5 \text{ RIC}$, $Q_3 + 1,5 \text{ RIC}$) y z robusto con la mediana y la MEDA. En la mortalidad hay 64 condados fuera de las vallas y 18 con $|z| > 3,5$; todos son condados reales (enclaves de altos ingresos con mortalidad muy baja, como Pitkin County, Colorado, o condados rurales muy envejecidos o pobres con mortalidad muy alta).
- **Multivariantes.** Distancia de Mahalanobis robusta con el determinante de covarianza mínimo (Rousseeuw y Van Driessen 1999) sobre las 25 explicativas: 1202 condados superan el cuantil 0,975 de la χ^2 (40,6), frente a 330 con la distancia clásica. La diferencia ilustra el *efecto máscara*: los atípicos inflan la covarianza clásica y se ocultan a sí mismos. Muchos son condados poco poblados con composiciones extremas (reservas indígenas, enclaves universitarios), auténticos y no errores.
- **En el modelo:** residuos estudentizados, apalancamiento y distancia de Cook (apartado 7.7).

Análisis exploratorio e inferencia clásica

Antes de modelar conviene conocer la respuesta, cuantificar con intervalos de confianza su centro y su dispersión, y examinar sus relaciones marginales con cada explicativa. Este capítulo aplica las herramientas de inferencia del curso (Wasserman 2004, caps. 6–10).

4.1 La respuesta: mortalidad por cáncer

La mortalidad media es de 178,66 muertes por 100 000 habitantes, con una desviación típica de 27,75. La tabla 4.1 recoge los intervalos de confianza al 95 % para los parámetros de posición y dispersión, cada uno construido con la cantidad pivotal adecuada:

- para la media, $\bar{X} \pm t_{n-1, \alpha/2} S/\sqrt{n}$, válido por el teorema central del límite aunque la distribución no sea normal (con $n = 3047$);
- para la varianza, el pivote $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$, que sí exige normalidad; por eso se acompaña de estimadores robustos;
- para la mediana, un intervalo de libre distribución basado en estadísticos de orden (cobertura exacta 95,4 %) y otro bootstrap percentil (Efron y Tibshirani 1993), que coinciden.

Tabla 4.1: Estimación puntual y por intervalos (95 %) de la mortalidad por cáncer

Parámetro	Estimación	IC 95 %	Método
Media	178,66	[177,68; 179,65]	pivote t de Student
Mediana	178,1	[177,0; 179,1]	estadísticos de orden (libre distribución)
Mediana	178,1	[177,0; 179,1]	bootstrap percentil (2000 réplicas)
Media recortada al 10 %	178,26	[177,32; 179,22]	bootstrap percentil
M-estimador de Huber	178,26	—	estimador robusto
Varianza	770,1	[732,9; 810,3]	pivote χ_{n-1}^2
Desviación típica	27,75	[27,07; 28,47]	pivote χ_{n-1}^2
MEDA	17,0	—	mediana de las desviaciones absolutas

La media, la mediana (178,1), la media recortada y el M-estimador de Huber (Huber 1964) prácticamente coinciden, de modo que los atípicos no desplazan el centro de la distribución. La asimetría es leve (0,275) y la curtosis en exceso moderada (1,350): las colas son algo más pesadas que las de la normal.

4.1.1 Normalidad

Todos los contrastes rechazan la normalidad exacta (tabla 4.2). Con más de tres mil observaciones cualquier desviación mínima es detectable, así que el resultado se interpreta junto al gráfico Q-Q: la forma es casi simétrica y las desviaciones se concentran en las colas. Para el modelo de regresión la hipótesis relevante no es la normalidad de la respuesta sino la de los errores, que se examina en el capítulo 7. El perfil de verosimilitud de Box-Cox (Box y Cox 1964) para la respuesta sin explicativas




Figura 4.1: Distribución de la mortalidad por cáncer: histograma con la densidad normal ajustada y la estimación núcleo, y gráfico cuantil-cuantil normal.

sitúa λ en 0,687 [0,536; 0,839]; la transformación se reconsidera, condicionada a las explicativas, en el capítulo 8.

Tabla 4.2: Contrastes de normalidad de la mortalidad

Contraste	Estadístico	p
Shapiro-Wilk	0,9903	< 0,001
Kolmogorov-Smirnov-Lilliefors	0,0280	0,001
D'Agostino-Pearson K^2	127,3633	< 0,001
Jarque-Bera	269,8196	< 0,001
Anderson-Darling	4,0742	0,010
χ^2 de Pearson (clases equiprobables) ($k = 50$, 47 g.l.)	94,2701	< 0,001
Asimetría (contraste de D'Agostino)	0,275	< 0,001
Curtosis de exceso (contraste de Anscombe-Glynn)	1,350	< 0,001

Anderson-Darling informa un p interpolado en tablas (acotado entre 0,01 y 0,15). Con n grande, cualquier desviación mínima resulta significativa: los contrastes se leen junto al gráfico Q-Q.

4.1.2 Independencia en el orden del fichero

Una prueba de rachas sobre los signos de las desviaciones respecto de la mediana, en el orden del fichero, encuentra 1172 rachas frente a 1522,5 esperadas bajo independencia ($z = -12,71$, $p < 0,001$). El fichero está ordenado por estado, de modo que los condados vecinos se parecen: es la primera señal de dependencia geográfica, que condicionará la inferencia del modelo.

4.2 Diferencias entre regiones

La mortalidad media difiere entre regiones censales (tabla 4.3): el Sur (189,0) supera a todas las demás y el Oeste (158,0) es la más baja. Como las varianzas difieren (Levene, $p < 0,001$), la comparación global se hace con el ANOVA de Welch ($F = 164,3$, 898,0 g.l. en el denominador, $p < 0,001$), confirmado por el contraste no paramétrico de Kruskal-Wallis ($H = 478,3$, $p < 0,001$). La región explica el 14,9 % de la variabilidad ($\eta^2 = 0,149$) y el estado, el 33,6 %. Las comparaciones por pares (tabla 4.4) muestran que sólo el Medio Oeste y el Noreste no difieren entre sí.


Tabla 4.3: Mortalidad por región censal

Región	<i>n</i>	Media	IC 95 %	Desv. típ.	Mediana
Sur	1383	189,0	[187,5; 190,4]	27,6	188,2
Medio Oeste	1029	174,5	[173,0; 176,0]	23,9	173,5
Noreste	217	172,5	[170,6; 174,4]	14,2	173,3
Oeste	418	158,0	[155,4; 160,7]	27,2	157,7

ANOVA: $F = 178,0$ (3 y 3043 g.l.), $p < 0,001$, $\eta^2 = 0,149$. Levene (mediana): $p < 0,001$. Welch: $F = 164,3$, $p < 0,001$.
Kruskal-Wallis: $H = 478,3$, $p < 0,001$.

Tabla 4.4: Comparaciones por pares entre regiones

Par	Diferencia	IC 95 % (Tukey)	<i>p</i> Tukey	<i>p</i> Mann-Whitney (Holm)
Medio Oeste – Noreste	2,0	[−2,9; 6,9]	0,731	0,263
Medio Oeste – Oeste	16,5	[12,6; 20,3]	< 0,001	< 0,001
Medio Oeste – Sur	−14,5	[−17,2; −11,7]	< 0,001	< 0,001
Noreste – Oeste	14,5	[9,0; 20,0]	< 0,001	< 0,001
Noreste – Sur	−16,4	[−21,2; −11,6]	< 0,001	< 0,001
Oeste – Sur	−30,9	[−34,6; −27,2]	< 0,001	< 0,001

**Figura 4.2:** Mortalidad por región censal: distribución en cada región y media con su intervalo de confianza al 95 %.

4.3 Dos contrastes de dos muestras

- **Pobreza.** Los condados con al menos un 20 % de población bajo el umbral de pobreza (830) tienen una mortalidad media de 193,5, frente a 173,1 en el resto: una diferencia de 20,4 muertes por 100 000 habitantes [18,1; 22,8] (Welch, $t = 17,24$), con un tamaño del efecto grande ($d = 0,78$).
- **Ensayos clínicos.** Los 1116 condados con algún ensayo clínico tienen una mortalidad $-6,2$ puntos menor (Welch $p < 0,001$; Mann-Whitney $p < 0,001$). Es una diferencia marginal que, como se verá, desaparece al ajustar por las características socioeconómicas: los ensayos se concentran en condados urbanos y ricos.

4.4 Asociaciones marginales

La figura 4.3 y la tabla B.3 (apéndice B) recogen la correlación de cada explicativa con la mortalidad, con su intervalo de confianza por la transformación z de Fisher y p corregidos por Holm (Holm 1979); 22 de las 25 son significativas. Las más fuertes son la incidencia ($r = 0,472$), el porcentaje de adultos con título universitario ($r = -0,485$), la renta mediana ($r = -0,452$), la cobertura sólo pública ($r = 0,449$) y la pobreza ($r = 0,429$). El gradiente por renta es monótono: la mortalidad media pasa de 202,7 en el decil más pobre a 159,1 en el más rico (ρ de Spearman $= -0,461$).





Figura 4.3: Correlación de Pearson de cada explicativa con la mortalidad, con su intervalo de confianza al 95 %.

Estas correlaciones son marginales: muchas explicativas están muy correlacionadas entre sí (figura 4.4), de modo que parte de cada asociación se debe a las demás. El modelo de regresión múltiple separa esas contribuciones.



Construcción del modelo

Entregable (a): pasos seguidos para construir el modelo

Partiendo de 25 explicativas candidatas y la región censal: (1) se eliminan una a una las variables con colinealidad severa; (2) se diagnostica la estructura del error del modelo máximo para elegir cómo hacer inferencia; (3) se seleccionan los efectos principales por eliminación hacia atrás con contrastes robustos; (4) se reincorporan las confusoras de las exposiciones de interés; (5) se contrastan interacciones respetando el principio jerárquico; y (6) se comparan los modelos anidados resultantes. Cada paso es una opción de la configuración y queda registrado en la corrida.

5.1 Especificación de partida

El modelo de partida incluye todas las explicativas que pueden serlo (capítulo 2), con las transformaciones logarítmicas de la población, la renta y los ensayos clínicos, y la región como variable cualitativa con el Sur de referencia. La incidencia se incluye: la mortalidad es, en buena medida, incidencia por letalidad, y omitirla haría que los coeficientes mezclaran ambas cosas. Con ella, el resto de coeficientes se interpreta a igual número de diagnósticos por habitante; el capítulo 6 compara ambos modelos (tabla 6.8).

Las explicativas continuas se *centran* en su media. El centrado no cambia el ajuste ni las pendientes de un modelo sin interacciones, pero hace interpretable la constante (mortalidad esperada de un condado medio del Sur) y, sobre todo, da sentido a los efectos principales cuando hay interacciones: cada uno es el efecto de su variable en la región de referencia y con las demás en su media, y desaparece la colinealidad no esencial entre una variable y su producto.

5.2 Colinealidad

Cuando una explicativa es casi combinación lineal de las demás, su coeficiente se estima con una varianza enorme y se vuelve inestable. Se mide con el factor de inflación de la varianza

$$\text{FIV}_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 es el coeficiente de determinación de la regresión de X_j sobre las demás explicativas: la varianza de $\hat{\beta}_j$ es FIV_j veces la que tendría con explicativas incorreladas. Su inversa es la *tolerancia* que imprime SPSS. Complementa al FIV el número de condición de Belsley (Belsley et al. 1980), que detecta dependencias que implican a varias variables a la vez.

El FIV máximo del modelo de partida es 25,9 y el número de condición 972,2. Se eliminó en cada paso la variable de mayor FIV, recalculando todos los FIV, hasta que ninguno superó 10 (tabla 5.1): salen seguro público, población casada, seguro privado y log(renta mediana). Las cuatro son redundantes con otra que permanece: el seguro público incluye al sólo público y el privado es casi su complementario; la población casada y la proporción de hogares de matrimonios miden casi lo mismo; y la renta mediana está fuertemente correlacionada, en sentido inverso, con la pobreza ($|r| > 0,85$ en los cuatro casos). Así,

la dimensión de la renta sigue representada en el modelo máximo por la pobreza. Tras la poda el FIV máximo es 6,88 y el número de condición 187,1.

Tabla 5.1: Poda iterativa por factor de inflación de la varianza (umbral 10)

Paso	Eliminada	FIV	Más correlada con	<i>r</i>
1	Seguro público	25,9	Solo seguro público	0,867
2	Población casada	14,6	Hogares de matrimonios	0,873
3	Seguro privado	13,9	Solo seguro público	-0,887
4	log(Renta mediana)	11,0	Pobreza	-0,855

Número de condición: 972,2 antes y 187,1 después de la poda.




Figura 5.1: Factor de inflación de la varianza de cada explicativa antes y después de la poda (escala logarítmica); la línea vertical marca el umbral de 10.

5.3 Estructura del error y estrategia de inferencia

Antes de seleccionar variables hay que decidir cómo se calculan los errores típicos, porque de ellos dependen todos los contrastes de la selección. El modelo máximo ($R^2 = 0,548$) presenta dos violaciones claras de las hipótesis clásicas:

- **Heterocedasticidad ligada a la población.** Una tasa calculada con pocas muertes es muy ruidosa: si las muertes de un condado de n habitantes se comportan como un proceso de Poisson, la varianza de su tasa es proporcional a $1/n$. La varianza de los residuos en el decil de condados más pequeños (758) es 6,8 veces la del decil más grande (112); el contraste de Breusch-Pagan frente a $1/n$ lo confirma ($LM = 201,9$, $p < 0,001$). Se estimó la función de varianza

$$\sigma^2(n) = a + \frac{b}{n}, \quad \hat{a} = 195,2, \quad \hat{b} = 2,136 \cdot 10^6 \quad (p < 0,001),$$

por mínimos cuadrados ponderados factibles iterados. Su lectura es sustantiva: en un condado de 10 000 habitantes el 52 % de la varianza residual es ruido de muestreo de la propia tasa; en uno de un millón, el 1 %.

- **Dependencia dentro de cada estado.** Los condados de un mismo estado comparten registro de cáncer, sistema sanitario y políticas. La correlación intraclase de los residuos por estado es 0,074 ($F = 5,41$, $p < 0,001$): los errores no son independientes.




Figura 5.2: Varianza residual media por decil de población. Izquierda: modelo inicial y función de varianza ajustada $a + b/n$. Derecha: modelo final, residuos MCO frente a residuos ponderados por la función de varianza (MCPF).

Ninguna de las dos violaciones sesga los coeficientes MCO, pero ambas invalidan sus errores típicos clásicos, $\hat{\sigma}^2(X^\top X)^{-1}$. Hay dos remedios:

1. **Mantener MCO y corregir la varianza.** El estimador «sándwich»

$$\widehat{\text{Var}}(\hat{\beta}) = (X^\top X)^{-1} \left(\sum_{g=1}^G X_g^\top \hat{\mathbf{e}}_g \hat{\mathbf{e}}_g^\top X_g \right) (X^\top X)^{-1}$$

agrupa los residuos por estado (G conglomerados), de modo que es válido con heterocedasticidad de cualquier forma y con correlación arbitraria dentro de cada estado (White 1980; Cameron y Miller 2015). Con $G = 48$ estados, los contrastes usan la t de Student con $G - 1 = 47$ grados de libertad, como recomiendan Cameron y Miller (2015) para un número moderado de conglomerados.

2. **Ponderar por $1/\hat{\sigma}^2(n)$ (MCPF),** más eficiente si la función de varianza es correcta.

Decisión. La orientación pide un modelo MCO, de modo que el estimador principal es MCO con errores típicos robustos por conglomerados de estado. Los errores típicos clásicos se presentan como salida tipo SPSS (apartado 6.2) y los HC3 (MacKinnon y White 1985) como referencia; la estimación ponderada por la función de varianza es una especificación de sensibilidad (capítulo 8). Todos los contrastes de la selección usan la covarianza por conglomerados.

5.4 Selección de variables

Se aplicó la eliminación hacia atrás: partiendo del modelo máximo (22 términos, $n = 2699$ condados con todas las variables), en cada paso se retira el término con mayor p en el contraste de Wald robusto mientras ese p supere $\alpha = 0,05$. La región, con tres indicadores, se contrasta como un único término (un F con tres grados de libertad). En 12 pasos salen, por este orden, pobreza, log(población), población asiática, sin bachillerato (18–24), empleo (16+), log(1 + ensayos per cápita), población negra, hogares de matrimonios, grado universitario (18–24), bachillerato (25+), población nativa o multirracial y seguro privado vía empleador (tabla 5.2).

Tabla 5.2: Trazo de la selección de variables (contrastes de Wald con covarianza robusta por conglomerados)

Paso	Acción	Término	<i>F</i>	<i>p</i>
1	sale	Pobreza	0,027	0,869
2	sale	log(Población)	0,019	0,890
3	sale	Población asiática	0,118	0,733
4	sale	Sin bachillerato (18–24)	0,112	0,739
5	sale	Empleo (16+)	0,993	0,324
6	sale	log(1 + ensayos per cápita)	1,125	0,294
7	sale	Población negra	1,198	0,279
8	sale	Hogares de matrimonios	0,333	0,566
9	sale	Grado universitario (18–24)	0,857	0,359
10	sale	Bachillerato (25+)	2,465	0,123
11	sale	Población nativa o multirracial	3,802	0,057
12	sale	Seguro privado vía empleador	1,792	0,187

Para comprobar que el resultado no es un artefacto del método se repitió la selección hacia delante y por pasos: las tres estrategias coinciden en 6 términos (bachillerato (18–24), grado universitario (25+), incidencia de cáncer, otra raza, región censal y solo seguro público). En cambio, la misma eliminación hacia atrás con errores típicos *clásicos* retiene 15 términos, 5 más (bachillerato (25+), seguro privado vía empleador, población negra, población nativa o multirracial y hogares de matrimonios): al ignorar la dependencia por estado y la heterocedasticidad subestima los errores típicos y declara significativas variables que no lo son.

5.5 Confusión

La selección por significación puede descartar una variable que, sin ser significativa, cambia el coeficiente de un factor de interés: una *confusora*. Se aplicó el criterio del cambio en la estimación (Maldonado y Greenland 1993) a las exposiciones socioeconómicas que motivan el estudio (educación, pobreza y renta): se reincorpora la variable eliminada cuya inclusión cambia más de un 10 % el coeficiente de alguna exposición retenida, y se repite hasta que ninguna lo hace. Se reincorpora bachillerato (25+): su ausencia cambia un 27,3 % el coeficiente de grado universitario (25+). Las dos variables describen la misma distribución educativa (la proporción con bachillerato y la proporción con título universitario), y estimar el efecto del título universitario sin controlar por el bachillerato mezclaría ambos escalones educativos.

5.6 Interacciones

Se contrastaron 6 interacciones con fundamento sustantivo: si los efectos de la incidencia, la educación, la cobertura sólo pública, el desempleo o la pobreza difieren entre regiones, y si el efecto de la incidencia depende del nivel educativo. Sólo se contrasta una interacción si sus efectos principales están en el modelo (principio jerárquico), y en cada ronda los *p* de todas las candidatas se corrigen por Holm para controlar la tasa de error de familia. Entran 2: Grado universitario (25+) × región y Desempleo (16+) × región (tabla 5.3). La primera tiene $F = 7,27$ ($p < 0,001$; corregido, $p = 0,002$); la segunda, $F = 4,22$ ($p = 0,010$; corregido, $p = 0,040$).

Tabla 5.3: Contraste de interacciones candidatas por rondas (corrección de Holm sobre las candidatas de cada ronda)

Ronda	Interacción	g. l.	F	p	p Holm	
1	Incidencia de cáncer $\times$ Región censal	3	2,49	0,072	0,216	
1	Grado universitario (25+) $\times$ Región censal	3	7,27	< 0,001	0,002	entra
1	Solo seguro público $\times$ Región censal	3	1,76	0,167	0,216	
1	Desempleo (16+) $\times$ Región censal	3	3,94	0,014	0,055	
1	Incidencia de cáncer $\times$ Grado universitario (25+)	1	2,89	0,096	0,216	
2	Incidencia de cáncer $\times$ Región censal	3	2,49	0,071	0,143	
2	Solo seguro público $\times$ Región censal	3	1,40	0,255	0,255	
2	Desempleo (16+) $\times$ Región censal	3	4,22	0,010	0,040	entra
2	Incidencia de cáncer $\times$ Grado universitario (25+)	1	4,68	0,036	0,107	
3	Incidencia de cáncer $\times$ Región censal	3	2,65	0,060	0,120	
3	Solo seguro público $\times$ Región censal	3	0,22	0,881	0,881	
3	Incidencia de cáncer $\times$ Grado universitario (25+)	1	5,16	0,028	0,083	

5.7 Comparación de modelos anidados

La tabla 5.4 compara, sobre la misma muestra de 2699 condados, el modelo con sólo la región, el máximo tras la poda, el seleccionado y el final con interacciones. Cada fila se contrasta con la anterior con el F parcial clásico y con el Wald robusto.

Tabla 5.4: Comparación de modelos anidados (misma muestra y mismos pesos)

Modelo	k	$\bar{R}^2$	AIC	BIC	F clásico		Wald robusto	
					F	p	F	p
Nulo (región)	3	0,154	25 083	25 107	—	—	—	—
Máximo (tras la poda)	24	0,544	23 436	23 584	110,70	< 0,001	106,52	< 0,001
Seleccionado (efectos principales)	13	0,537	23 462	23 545	4,35	< 0,001	2,13	0,036
Final (con interacciones)	19	0,543	23 433	23 551	6,85	< 0,001	5,71	< 0,001

Cada fila se compara con la anterior (bloque de términos que se añade o se retira). El F clásico supone errores independientes y homocedásticos; el Wald robusto usa la covarianza por conglomerados de estado, la misma que guía la selección.

Tres lecturas:

- Las explicativas aportan muchísimo frente a la región sola ($\bar{R}^2$ pasa de 0,154 a 0,544).
- Los 11 parámetros que retira la selección no son significativos uno a uno, pero conjuntamente el Wald robusto da $p = 0,036$: aportan, en bloque, una mejora pequeña del ajuste ($\bar{R}^2$ de 0,537 frente a 0,544). El BIC, que penaliza más la complejidad, prefiere el modelo seleccionado (23 545,0 frente a 23 584,0); el AIC prefiere el máximo. Se opta por el modelo parsimonioso para interpretar, y el modelo máximo se reestima como especificación de sensibilidad (capítulo 8) para comprobar que las conclusiones no dependen de esta elección.
- Las interacciones mejoran el ajuste de forma significativa con ambos contrastes (Wald robusto $p < 0,001$) y el modelo final tiene el menor AIC de los cuatro.

Muestra de estimación. La selección y la comparación se hacen sobre los 2699 condados con todas las candidatas, para que todos los modelos sean comparables. Una vez fijados los términos, el modelo final se reestima con todos los condados completos en sus variables, 2840: excluir condados por variables que el modelo no usa sólo restaría precisión.

El modelo final

6.1 Especificación y coeficientes

El modelo final, estimado por MCO con 2840 condados de 48 estados, es

$$\begin{aligned} \widehat{\text{Mortalidad}} = & \beta_0 + \beta_1 \text{ Incidencia} + \beta_2 \text{ Edad mediana} + \beta_3 \text{ Tamaño del hogar} \\ & + \beta_4 \text{ Bachillerato 18-24} + \beta_5 \text{ Grado universitario 25+} + \beta_6 \text{ Bachillerato 25+} \\ & + \beta_7 \text{ Desempleo} + \beta_8 \text{ Sólo seguro público} + \beta_9 \text{ Otra raza} + \beta_{10} \text{ Natalidad} \\ & + \sum_r \gamma_r \text{ Región}_r + \sum_r \delta_r (\text{Grado universitario} \times \text{Región}_r) \\ & + \sum_r \eta_r (\text{Desempleo} \times \text{Región}_r), \end{aligned}$$

con las explicativas continuas centradas en su media y $r \in \{\text{Noreste, Medio Oeste, Oeste}\}$ (el Sur es la referencia): 19 regresores además de la constante. La tabla 6.1 recoge las estimaciones con errores típicos robustos por conglomerados de estado e intervalos de confianza con la t de 47 grados de libertad.

Tabla 6.1: Coeficientes del modelo final de efectos (MCO con errores típicos robustos por conglomerados de estado)

Término	$\hat{\beta}$	E. T.	t	p	IC 95 %	Beta
Constante	184,526	1,319	139,95	< 0,001	[181,873; 187,178]	
Incidencia de cáncer	0,187	0,019	9,61	< 0,001	[0,148; 0,226]	0,379
Edad mediana	-0,788	0,187	-4,22	< 0,001	[-1,164; -0,413]	-0,147
Tamaño medio del hogar	-12,875	3,292	-3,91	< 0,001	[-19,499; -6,252]	-0,115
Bachillerato (18-24)	0,241	0,064	3,76	< 0,001	[0,112; 0,370]	0,078
Grado universitario (25+)	-1,054	0,255	-4,14	< 0,001	[-1,566; -0,542]	-0,207
Desempleo (16+)	0,366	0,284	1,29	0,204	[-0,205; 0,937]	0,045
Solo seguro público	0,892	0,214	4,18	< 0,001	[0,463; 1,322]	0,197
Otra raza	-0,660	0,210	-3,14	0,003	[-1,082; -0,238]	-0,084
Natalidad	-0,381	0,249	-1,53	0,132	[-0,883; 0,120]	-0,027
Región: Noreste	-15,683	2,316	-6,77	< 0,001	[-20,343; -11,023]	
Región: Medio Oeste	-4,327	2,419	-1,79	0,080	[-9,194; 0,541]	
Región: Oeste	-14,131	2,756	-5,13	< 0,001	[-19,675; -8,586]	
Bachillerato (25+)	0,354	0,192	1,85	0,071	[-0,031; 0,739]	0,091
Grado universitario (25+) × Noreste	0,844	0,219	3,86	< 0,001	[0,404; 1,285]	
Grado universitario (25+) × Medio Oeste	0,229	0,308	0,74	0,461	[-0,391; 0,849]	
Grado universitario (25+) × Oeste	-0,031	0,257	-0,12	0,905	[-0,547; 0,485]	
Desempleo (16+) × Noreste	0,903	0,555	1,63	0,110	[-0,214; 2,020]	
Desempleo (16+) × Medio Oeste	1,478	0,446	3,31	0,002	[0,581; 2,375]	
Desempleo (16+) × Oeste	-0,429	0,688	-0,62	0,536	[-1,813; 0,955]	

$n = 2840$ condados de 48 estados. Explicativas continuas centradas en su media: la constante es la mortalidad esperada de un condado medio del Sur. Inferencia con t de 47 g.l. Beta: coeficiente tipificado.

6.2 Salida tipo SPSS: R^2 , $\bar{R}^2$ ajustado y RMSE

Entregable (b): salida del software

El modelo explica el 55,8 % de la variabilidad de la mortalidad entre condados: $R^2 = 0,558$ y $\bar{R}^2 = 0,555$. El error típico de la estimación es $\hat{\sigma} = \sqrt{\text{SCE}/(n - k - 1)} = 18,50$ y la raíz del error cuadrático medio dentro de la muestra, $\text{RMSE} = \sqrt{\text{SCE}/n} = 18,44$ muertes por 100 000 habitantes. Fuera de la muestra, la validación cruzada de esta especificación da un RMSE de 19,11 y la partición de prueba, 18,18 (capítulo 9).

Las tablas 6.2 a 6.4 reproducen las tablas que imprime el procedimiento REGRESSION de SPSS: resumen del modelo, ANOVA y coeficientes con errores típicos clásicos, coeficientes tipificados (Beta), tolerancia y FIV. La sintaxis del apéndice A, generada automáticamente a partir de la corrida, aplica la misma depuración sobre `practica.sav` y obtiene exactamente estas cifras.

Tabla 6.2: Resumen del modelo final (salida tipo SPSS)

R	R^2	$\bar{R}^2$	E. T. estimación	RMSE	D-W	F	g. l. ₁	g. l. ₂	p
0,747	0,558	0,555	18,50	18,44	1,878	187,34	19	2820	< 0,001

E. T. de la estimación: $\sqrt{\text{SCE}/(n - k - 1)}$; RMSE: $\sqrt{\text{SCE}/n}$, ambos dentro de la muestra. D-W: Durbin-Watson. El F y su p son los clásicos que imprime SPSS.

Tabla 6.3: Tabla ANOVA del modelo final

Fuente	Suma de cuadrados	g. l.	Cuadrado medio	F	p
Regresión (SCR)	1 218 548,0	19	64 134,1	187,34	< 0,001
Residual (SCE)	965 407,2	2820	342,34		
Total (SCT)	2 183 955,0	2839			

$R^2 = 0,558$, $\bar{R}^2 = 0,555$. Contraste global robusto (Wald, cluster): $F = 94,3$, $p < 0,001$.

Recuérdese que

$$R^2 = 1 - \frac{\text{SCE}}{\text{SCT}}, \quad \bar{R}^2 = 1 - \frac{\text{SCE}/(n - k - 1)}{\text{SCT}/(n - 1)} = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}.$$

El $\bar{R}^2$ ajustado penaliza el número de regresores; con n tan grande frente a k apenas difiere del R^2 . Un $\bar{R}^2$ del orden de 0,56 es alto para datos ecológicos transversales: buena parte de la variabilidad restante es ruido de muestreo de las tasas de los condados pequeños (apartado 5.3), que ninguna explicativa puede capturar.

El contraste global clásico ($F = 187,3$) y su versión robusta (Wald con covarianza por conglomerados, $F = 94,3$, $p < 0,001$) rechazan con claridad que todos los coeficientes sean nulos.

Tabla 6.4: Coeficientes del modelo final con errores típicos clásicos (salida tipo SPSS)

Término	B	E. T.	Beta	t	Sig.	IC 95 %	Tol.	FIV
Constante	184,526	0,545		338,37	< 0,001	[183,457; 185,595]		
Incidencia de cáncer	0,187	0,007	0,379	27,66	< 0,001	[0,173; 0,200]	0,835	1,20
Edad mediana	-0,788	0,095	-0,147	-8,31	< 0,001	[-0,974; -0,602]	0,501	1,99
Tamaño medio del hogar	-12,875	2,004	-0,115	-6,42	< 0,001	[-16,805; -8,945]	0,486	2,06
Bachillerato (18-24)	0,241	0,047	0,078	5,17	< 0,001	[0,150; 0,333]	0,684	1,46
Grado universitario (25+)	-1,054	0,160	-0,207	-6,60	< 0,001	[-1,367; -0,741]	0,160	6,25
Desempleo (16+)	0,366	0,178	0,045	2,06	0,040	[0,017; 0,715]	0,323	3,09

(continúa)

(continuación)

Término	B	E. T.	Beta	t	Sig.	IC 95 %	Tol.	FIV
Solo seguro público	0,892	0,093	0,197	9,63	< 0,001	[0,711; 1,074]	0,374	2,67
Otra raza	-0,660	0,118	-0,084	-5,60	< 0,001	[-0,891; -0,429]	0,702	1,42
Natalidad	-0,381	0,187	-0,027	-2,04	0,042	[-0,749; -0,014]	0,888	1,13
Región: Noreste	-15,683	1,685		-9,30	< 0,001	[-18,988; -12,378]	0,601	1,66
Región: Medio Oeste	-4,327	0,957		-4,52	< 0,001	[-6,202; -2,451]	0,632	1,58
Región: Oeste	-14,131	1,221		-11,57	< 0,001	[-16,525; -11,737]	0,668	1,50
Bachillerato (25+)	0,354	0,096	0,091	3,68	< 0,001	[0,165; 0,542]	0,257	3,89
Grado universitario (25+) × Noreste	0,844	0,265		3,19	0,001	[0,326; 1,363]	0,555	1,80
Grado universitario (25+) × Medio Oeste	0,229	0,187		1,23	0,220	[-0,137; 0,595]	0,554	1,80
Grado universitario (25+) × Oeste	-0,031	0,192		-0,16	0,873	[-0,408; 0,346]	0,492	2,03
Desempleo (16+) × Noreste	0,903	0,774		1,17	0,243	[-0,615; 2,421]	0,791	1,26
Desempleo (16+) × Medio Oeste	1,478	0,273		5,42	< 0,001	[0,944; 2,012]	0,446	2,24
Desempleo (16+) × Oeste	-0,429	0,325		-1,32	0,187	[-1,066; 0,209]	0,618	1,62

Errores típicos clásicos $\hat{\sigma}^2(X^T X)^{-1}$, como en el procedimiento REGRESSION; la sintaxis `spss/modelo_final.sps` los reproduce. La inferencia del informe usa los robustos (tabla 6.5).

6.2.1 Errores típicos clásicos, HC3 y por conglomerados

Los coeficientes son idénticos con las tres estimaciones de la covarianza; cambian sus errores típicos (tabla 6.5). Los robustos por conglomerados son, en casi todos los términos, claramente mayores que los clásicos (la columna «Razón» de la tabla): la inferencia clásica sería optimista. Con errores típicos clásicos parecerían significativos la natalidad, el bachillerato de 25 años o más, el desempleo en el Sur y la diferencia entre el Medio Oeste y el Sur; con los robustos no lo son.

Tabla 6.5: Errores típicos del modelo final: clásicos, HC3 y por conglomerados de estado

Término	$\hat{\beta}$	Clásico	HC3	Cluster	Razón	p clásico	p cluster
Incidencia de cáncer	0,187	0,007	0,012	0,019	2,88	< 0,001	< 0,001
Edad mediana	-0,788	0,095	0,114	0,187	1,97	< 0,001	< 0,001
Tamaño medio del hogar	-12,875	2,004	2,758	3,292	1,64	< 0,001	< 0,001
Bachillerato (18-24)	0,241	0,047	0,061	0,064	1,38	< 0,001	< 0,001
Grado universitario (25+)	-1,054	0,160	0,183	0,255	1,60	< 0,001	< 0,001
Desempleo (16+)	0,366	0,178	0,218	0,284	1,60	0,040	0,204
Solo seguro público	0,892	0,093	0,108	0,214	2,31	< 0,001	< 0,001
Otra raza	-0,660	0,118	0,140	0,210	1,78	< 0,001	0,003
Natalidad	-0,381	0,187	0,255	0,249	1,33	0,042	0,132
Región: Noreste	-15,683	1,685	1,294	2,316	1,37	< 0,001	< 0,001
Región: Medio Oeste	-4,327	0,957	0,950	2,419	2,53	< 0,001	0,080
Región: Oeste	-14,131	1,221	1,437	2,756	2,26	< 0,001	< 0,001
Bachillerato (25+)	0,354	0,096	0,122	0,192	1,99	< 0,001	0,071
Grado universitario (25+) × Noreste	0,844	0,265	0,198	0,219	0,83	0,001	< 0,001
Grado universitario (25+) × Medio Oeste	0,229	0,187	0,188	0,308	1,65	0,220	0,461
Grado universitario (25+) × Oeste	-0,031	0,192	0,217	0,257	1,33	0,873	0,905
Desempleo (16+) × Noreste	0,903	0,774	0,546	0,555	0,72	0,243	0,110
Desempleo (16+) × Medio Oeste	1,478	0,273	0,317	0,446	1,64	< 0,001	0,002
Desempleo (16+) × Oeste	-0,429	0,325	0,462	0,688	2,12	0,187	0,536

Razón: E. T. por conglomerados entre E. T. clásico. Una razón mayor que 1 indica que la inferencia clásica es optimista, por la dependencia dentro de cada estado y la heterocedasticidad.

6.3 Interpretación

Entregable (e): interpretación del modelo

Cada coeficiente es el cambio esperado en la mortalidad (muertes por 100 000 habitantes) por una unidad más de su explicativa, manteniendo constantes las demás. Son asociaciones entre condados, no efectos causales: el diseño es observacional y ecológico. Para comparar variables medidas en escalas distintas, la tabla 6.6 expresa cada efecto como el cambio al pasar del primer al tercer cuartil de la explicativa (rango intercuartílico, RIC).

6.3.1 La constante y las regiones

Como las explicativas están centradas, la constante (184,526) es la mortalidad esperada de un condado del Sur con todas las explicativas en su media. A igualdad de las demás características, un condado medio del Noreste tiene -15,683 muertes por 100 000 habitantes respecto del Sur ($[-20,343; -11,023]$), uno del Oeste -14,131 ($[-19,675; -8,586]$) y uno del Medio Oeste -4,327 ($[-9,194; 0,541]$; $p = 0,080$). La composición socioeconómica explica una parte importante de las diferencias regionales: la brecha bruta entre el Sur y el Oeste, 31,8 muertes, se reduce a 14,1 al ajustar, de modo que el modelo explica el 56 % de ella (figura 6.1).




Figura 6.1: Mortalidad media bruta y ajustada por región. La ajustada es la predicción del modelo para un condado de esa región con las explicativas en su media.

6.3.2 Efectos principales

- **Incidencia.** Cada caso diagnosticado más por 100 000 habitantes se asocia con 0,187 muertes más $[0,148; 0,226]$. Pasar del primer al tercer cuartil (66,40 casos) supone 12,4 muertes más $[9,8; 15,0]$; es, con diferencia, la explicativa más importante ($\text{Beta} = 0,379$).
- **Cobertura sanitaria sólo pública.** Cada punto porcentual más de residentes cuyo único seguro es público (*Medicaid* o *Medicare*) se asocia con 0,892 muertes más $[0,463; 1,322]$; del primer al tercer cuartil, 7,4 $[3,8; 10,9]$. Es un indicador de pobreza, edad avanzada y peor acceso a la atención especializada.
- **Educación.** El porcentaje de adultos con título universitario tiene el efecto protector más claro, pero su magnitud depende de la región (apartado 6.3.3). El porcentaje de jóvenes de 18 a 24 años cuyo nivel máximo es el bachillerato se asocia con más mortalidad (0,241 por punto, $[0,112; 0,370]$), como indicador de menor acceso a estudios superiores. El de adultos con bachillerato (0,354, $p = 0,071$) no es significativo, pero se mantiene por ser confusor del efecto del título universitario.

- **Edad mediana.** Cada año más de edad mediana se asocia con $-0,788$ muertes $[-1,164; -0,413]$. El signo negativo no significa que envejecer proteja: compara condados con la misma incidencia y el mismo perfil socioeconómico. Una explicación compatible, que este diseño no permite contrastar, es la migración de jubilados con mejor salud y recursos hacia condados envejecidos.
- **Tamaño medio del hogar.** Una persona más por hogar se asocia con $-12,875$ muertes $[-19,499; -6,252]$; como el rango intercuartílico es sólo de 0,26 personas, el efecto entre condados típicos es de $-3,3$ $[-5,1; -1,6]$.
- **Otra raza.** Cada punto porcentual más de población de otras razas (sobre todo hispana, que en el censo puede declararse en esta categoría) se asocia con $-0,660$ muertes $[-1,082; -0,238]$, en línea con la menor mortalidad por cáncer documentada en la población hispana.
- **Natalidad** ($-0,381$, $p = 0,132$): no significativa.

Tabla 6.6: Magnitud de los efectos: por unidad y al pasar del primer al tercer cuartil

Variable	Unidad	Por unidad	IQR	Efecto Q1→Q3	IC 95 %
Incidencia de cáncer	casos/100 000 hab.	0,187	66,40	12,4	[9,8; 15,0]
Edad mediana	años	$-0,788$	6,10	$-4,8$	$[-7,1; -2,5]$
Tamaño medio del hogar	personas	$-12,875$	0,26	$-3,3$	$[-5,1; -1,6]$
Bachillerato (18–24)	%	0,241	11,50	2,8	[1,3; 4,3]
Solo seguro público	%	0,892	8,25	7,4	[3,8; 10,9]
Otra raza	%	$-0,660$	1,88	$-1,2$	$[-2,0; -0,4]$
Natalidad	%	$-0,381$	1,97	$-0,8$	$[-1,7; 0,2]$
Bachillerato (25+)	%	0,354	9,25	3,3	$[-0,3; 6,8]$

Muertes por 100 000 habitantes, manteniendo constantes las demás variables del modelo.




Figura 6.2: Efecto de cada explicativa al pasar del primer al tercer cuartil, con su intervalo de confianza al 95 % (errores típicos por conglomerados). Las variables con interacción muestran un efecto por región; los marcadores huecos no son significativos.

6.3.3 Interacciones: efectos que dependen de la región

Con interacciones, el coeficiente de una variable en una región es la suma de su efecto principal (el del Sur) y de la interacción correspondiente; su error típico se obtiene de la combinación lineal de

coeficientes con la matriz de covarianzas robusta. La tabla 6.7 y la figura 6.3 recogen las pendientes resultantes.

- **Título universitario.** Cada punto porcentual más de adultos con título universitario se asocia con $-1,054$ muertes en el Sur ($p < 0,001$), $-1,085$ en el Oeste ($p < 0,001$) y $-0,825$ en el Medio Oeste ($p = 0,025$). En el Noreste la pendiente es $-0,209$ y no significativa ($p = 0,416$): el gradiente educativo es mucho más débil allí.
- **Desempleo.** En el Sur la pendiente es $0,366$ ($p = 0,204$) y en el Oeste $-0,063$ ($p = 0,926$), ninguna significativa; en cambio, en el Medio Oeste cada punto de desempleo se asocia con $1,844$ muertes más ($p < 0,001$) y en el Noreste con $1,269$ ($p = 0,019$).

Tabla 6.7: Efecto de las variables que interaccionan con la región: pendiente específica de cada región

Variable	Región	Pendiente	IC 95 %	p	Efecto Q1→Q3
Grado universitario (25+)	Sur	-1,054	[-1,566; -0,542]	< 0,001	-7,1
	Noreste	-0,209	[-0,723; 0,304]	0,416	-1,4
	Medio Oeste	-0,825	[-1,542; -0,108]	0,025	-5,5
	Oeste	-1,085	[-1,600; -0,569]	< 0,001	-7,3
Desempleo (16+)	Sur	0,366	[-0,205; 0,937]	0,204	1,5
	Noreste	1,269	[0,221; 2,317]	0,019	5,3
	Medio Oeste	1,844	[0,940; 2,749]	< 0,001	7,7
	Oeste	-0,063	[-1,417; 1,291]	0,926	-0,3

Pendiente en la región R : $\hat{\beta}_x + \hat{\beta}_{x \times R}$, con $\widehat{\text{Var}} = \widehat{\text{Var}}(\hat{\beta}_x) + \widehat{\text{Var}}(\hat{\beta}_{x \times R}) + 2 \widehat{\text{Cov}}$.




Figura 6.3: Pendiente del título universitario y del desempleo en cada región, con su intervalo de confianza al 95 %. Marcador hueco: pendiente no significativa.


6.3.4 ¿Qué cambia si no se ajusta por la incidencia?

Incluir la incidencia cambia la pregunta: con ella, los demás coeficientes describen la mortalidad a igual número de diagnósticos, es decir, sobre todo la supervivencia; sin ella, la asociación total, que incluye también el riesgo de enfermar. La tabla 6.8 compara ambos ajustes sobre la misma muestra. Sin la incidencia el R^2 cae de 0,558 a 0,438, y algunos coeficientes cambian mucho: el del desempleo crece un 141,7 %, porque el desempleo se asocia también con mayor incidencia (por ejemplo, a través del tabaquismo). El del título universitario cambia sólo un 13,1 %: su asociación con la mortalidad no pasa por la incidencia.

Tabla 6.8: Coeficientes con y sin ajustar por la incidencia (misma muestra y mismos pesos)

Término	Con incidencia	Sin incidencia	Cambio (%)
Edad mediana	-0,788	-1,240	-57,3
Tamaño medio del hogar	-12,875	-21,614	-67,9
Bachillerato (18-24)	0,241	0,326	35,2
Grado universitario (25+)	-1,054	-0,916	13,1
Desempleo (16+)	0,366	0,885	141,7
Solo seguro público	0,892	0,884	-0,9
Otra raza	-0,660	-1,127	-70,9
Natalidad	-0,381	-0,857	-124,6
Región: Noreste	-15,683	-9,303	40,7
Región: Medio Oeste	-4,327	-4,934	-14,0
Región: Oeste	-14,131	-17,237	-22,0
Bachillerato (25+)	0,354	0,474	34,1

R^2 con incidencia: 0,558; sin ella: 0,438. Un cambio grande indica que la incidencia es confusora (o mediadora) de esa asociación.

**Figura 6.4:** Cambio relativo de cada coeficiente al retirar la incidencia del modelo. Las líneas discontinuas marcan ± 10 %.

Diagnóstico del modelo

Entregable (d): diagnóstico

Se contrastan las hipótesis del modelo lineal sobre los residuos del modelo final: linealidad, independencia de los errores, homocedasticidad, normalidad y ausencia de multicolinealidad, y se identifican las observaciones influyentes. La tabla 7.1 resume los contrastes; para cada violación se indica cómo la absorbe la estrategia de inferencia.

Bajo las hipótesis clásicas, $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ con $E(\boldsymbol{\varepsilon} | \mathbf{X}) = \mathbf{0}$ y $\text{Var}(\boldsymbol{\varepsilon} | \mathbf{X}) = \sigma^2 \mathbf{I}$, el estimador MCO $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ es el de menor varianza entre los lineales insesgados (teorema de Gauss-Markov) y, si además los errores son normales, los contrastes t y F son exactos. Conviene separar qué hipótesis afecta a qué:

- la **linealidad** (media condicional bien especificada) es la única cuya violación sesga los coeficientes;
- la **homocedasticidad** y la **independencia** afectan a la varianza de $\hat{\boldsymbol{\beta}}$ y, por tanto, a los errores típicos, intervalos y contrastes;
- la **normalidad** sólo es necesaria para la inferencia exacta en muestras pequeñas; con n grande, el teorema central del límite garantiza la normalidad aproximada de $\hat{\boldsymbol{\beta}}$.

Tabla 7.1: Diagnóstico de las hipótesis del modelo

Hipótesis	Contraste	Estadístico	p	Decisión al 5 %
Linealidad	RESET de Ramsey (potencias 2 y 3)	1,291	0,275	no se rechaza H_0
Normalidad	Shapiro-Wilk (residuos tipificados)	0,9750	< 0,001	se rechaza H_0
	Jarque-Bera	952,9	< 0,001	se rechaza H_0
Homocedasticidad	Breusch-Pagan, MCO inicial	262,7	< 0,001	se rechaza H_0
	Breusch-Pagan, modelo final	73,0	< 0,001	se rechaza H_0
	Frente a 1/población, MCO inicial	201,9	< 0,001	se rechaza H_0
	Frente a 1/población, modelo final	209,99	< 0,001	se rechaza H_0
Independencia	Durbin-Watson (orden del fichero)	1,878	—	
	Rachas de los signos	-3,33	< 0,001	se rechaza H_0
	Correlación intraclass por estado	0,079	< 0,001	se rechaza H_0
Media cero	Media de los residuos	$-1,6 \times 10^{-13}$	—	por construcción

La dependencia dentro de cada estado y la heterocedasticidad se absorben con errores típicos robustos por conglomerados; la falta de normalidad, con el bootstrap por conglomerados, que no la supone.

7.1 Linealidad

El contraste RESET de Ramsey (1969) añade al modelo las potencias segunda y tercera de los valores ajustados: si la media condicional no fuera lineal en las explicativas, esos términos captarían la curvatura omitida. No se rechaza la especificación ($F = 1,291$, $p = 0,275$). Además, para cada explicativa continua se contrastó un término cuadrático con corrección de Holm: el número de curvaturas significativas es 0 (ninguna). Los gráficos de residuos parciales (componente más residuo, figura 7.2) lo confirman: la curva




Figura 7.1: Gráficos de diagnóstico del modelo final: residuos tipificados frente a valores ajustados, gráfico cuantil-cuantil normal, escala-localización y residuos estudentizados frente al apalancamiento (el área de cada punto es proporcional a la distancia de Cook).

suavizada sigue la recta del modelo en el rango donde están casi todos los datos. Las transformaciones logarítmicas de la depuración (D10) contribuyen a esta linealidad.




Figura 7.2: Residuos parciales de las seis explicativas con mayor efecto: la recta es la contribución estimada por el modelo y la curva, un suavizado LOWESS de los puntos.

7.2 Independencia de los errores

El estadístico de Durbin y Watson (1950),

$$d = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2} \approx 2(1 - \hat{\rho}_1),$$

vale 1,878, cerca de 2: no hay una autocorrelación de primer orden apreciable. Pero el contraste se diseñó para series temporales, en las que el orden de las filas tiene sentido; en datos transversales su resultado depende del orden arbitrario del fichero. Aquí el fichero está agrupado por estado, de modo que la pregunta pertinente es si los condados de un mismo estado tienen errores parecidos. Lo tienen:

- la prueba de rachas sobre los signos de los residuos en el orden del fichero da $z = -3,33$ ($p < 0,001$): menos rachas de las esperadas, es decir, residuos del mismo signo agrupados;
- la correlación intraclase de los residuos por estado es 0,079 ($F = 6,01$, $p < 0,001$), y en un modelo mixto con intercepto aleatorio por estado la varianza entre estados representa una proporción 0,118 de la varianza total.

La dependencia dentro del estado no sesga los coeficientes, pero sí hace que los errores típicos clásicos sean demasiado pequeños: es la razón de usar errores típicos por conglomerados de estado (apartado 5.3).

7.3 Homocedasticidad

El gráfico de residuos frente a valores ajustados no muestra un embudo marcado, pero los contrastes detectan heterocedasticidad: Breusch-Pagan en la versión robusta de Koenker (1981) ($LM = 73,0$, $p < 0,001$), White con los valores ajustados y sus cuadrados ($LM = 34,99$, $p < 0,001$) y, sobre todo, el contraste frente a $1/n$ ($LM = 209,99$, $p < 0,001$), que identifica la fuente: la población del condado (apartado 5.3). El cociente de Goldfeld-Quandt entre la varianza residual del tercio de condados más pequeños y la del tercio más grande es 3,71. La heterocedasticidad no sesga los coeficientes; la inferencia la absorbe con los errores típicos robustos, y la estimación ponderada por la función de varianza (capítulo 8) confirma que los coeficientes apenas cambian cuando se pondera.

7.4 Normalidad de los residuos

Los residuos tipificados tienen asimetría 0,184 y curtosis en exceso 2,81: son casi simétricos pero con colas más pesadas que la normal, como muestra el gráfico Q-Q. Shapiro-Wilk ($W = 0,9750$, $p < 0,001$) y Jarque-Bera ($JB = 952,9$, $p < 0,001$) rechazan la normalidad exacta, como es esperable con casi tres mil residuos y una mezcla de condados de tamaños muy distintos (los pequeños aportan los residuos extremos). Las consecuencias son limitadas: los estimadores siguen siendo insesgados, y con $n = 2840$ la distribución de $\hat{\beta}$ es aproximadamente normal. Como comprobación independiente, el bootstrap por conglomerados, que no supone normalidad, produce intervalos muy parecidos a los paramétricos (capítulo 8).

7.5 Multicolinealidad

Tras la poda (apartado 5.2), el FIV máximo entre los efectos principales del modelo final es 6,25 (tolerancia mínima por encima de 0,1) y el número de condición 6,0, lejos de los umbrales habituales (10 y 30). Las tolerancias y FIV de cada coeficiente están en la tabla 6.4. Los términos de interacción comparten información con sus efectos principales por construcción, pero el centrado previo elimina la colinealidad no esencial.

7.6 Media de los residuos

Al incluir la constante, los residuos MCO suman cero por construcción (su media es $-1,6 \times 10^{-13}$, error de redondeo). La hipótesis relevante, $E(\varepsilon | X) = 0$, es la de linealidad, ya examinada.

7.7 Observaciones atípicas e influyentes

Se calcularon, para cada condado, el apalancamiento h_{ii} (diagonal de la matriz sombrero $H = X(X^T X)^{-1} X^T$), el residuo estudentizado externamente r_i^* , la distancia de Cook (1977),

$$D_i = \frac{r_i^2}{k+1} \frac{h_{ii}}{1-h_{ii}},$$

y los DFBETAS de cada coeficiente:

- 276 condados tienen apalancamiento mayor que $2(k+1)/n = 0,0141$: combinaciones poco habituales de explicativas, no necesariamente problemáticas;

- 29 tienen $|r_i^*| > 3$; el mayor es Madison County, Mississippi ($r^* = 7,35$: mortalidad observada 292,5 frente a 158,4 ajustada);
- 185 superan el umbral orientativo $D_i > 4/n = 0,00141$, pero 0 superan la mediana de la F de referencia, el criterio de influencia grave: el más influyente, Williamsburg city, Virginia, tiene $D = 0,098$.

Tabla 7.2: Los diez condados más influyentes (distancia de Cook)

Condado	y	$\hat{y}$	r^*	h_{ii}	Cook
Williamsburg city, Virginia	162,1	270,5	-6,05	0,051	0,0977
De Baca County, New Mexico	243,6	158,7	4,75	0,060	0,0716
Crowley County, Colorado	110,7	164,2	-3,02	0,082	0,0407
Nome Census Area, Alaska	277,6	201,4	4,19	0,027	0,0246
Wibaux County, Montana	214,4	141,1	4,03	0,028	0,0232
Madison County, Mississippi	292,5	158,4	7,35	0,008	0,0220
Sioux County, North Dakota	259,1	210,0	2,71	0,038	0,0146
Bethel Census Area, Alaska	218,8	168,2	2,79	0,036	0,0145
North Slope Borough, Alaska	256,9	175,6	4,44	0,013	0,0128
Pitkin County, Colorado	59,7	95,9	-2,01	0,054	0,0115

r^* : residuo estudentizado externamente; h_{ii} : apalancamiento.

Ningún condado domina el ajuste. Aun así, se reestimó el modelo sin los 185 condados con $D_i > 4/n$ y con regresión robusta de Huber, que pondera a la baja 618 condados con residuos grandes en lugar de eliminarlos (capítulo 8): las conclusiones no cambian. Los atípicos detectados son condados reales, por lo que se mantienen en el modelo.

Análisis de sensibilidad

Varias decisiones del análisis son razonables pero discutibles: estimar por MCO y no por mínimos cuadrados ponderados, seleccionar variables, analizar casos completos, conservar los atípicos o tratar la dependencia por estado sólo a través de los errores típicos. Para comprobar que las conclusiones no dependen de ellas, el modelo final se reestimó bajo 10 especificaciones alternativas y con un bootstrap por conglomerados (tabla 8.1 y figura 8.1):

Ponderación (MCPF).

Pesos $1/\hat{\sigma}^2(n)$ con la función de varianza estimada: el estimador eficiente si la heterocedasticidad se debe al tamaño del condado.

Modelo máximo.

Todas las candidatas tras la poda, sin selección de variables (apartado 5.7).

Efectos fijos de estado.

Una indicadora por estado: los coeficientes se estiman sólo con la variación entre condados del mismo estado, lo que elimina cualquier factor estatal no medido (registro, políticas sanitarias, clima). La región desaparece, absorbida por los estados.

Modelo mixto.

Intercepto aleatorio por estado, que modela explícitamente la dependencia intraestatal en lugar de corregirla en los errores típicos.

Regresión robusta de Huber.

M-estimador que pondera a la baja los residuos grandes (Huber 1964): resistente a los atípicos en la respuesta.

Sin observaciones influyentes.

Reajuste sin los condados con distancia de Cook mayor que $4/n$ (2655 condados restantes).

Imputación múltiple.

Los 3047 condados, con los ausentes imputados en 20 conjuntos y los resultados combinados por las reglas de Rubin (capítulo 3).

Bootstrap por conglomerados.

999 remuestreos de estados completos con reemplazo; los intervalos percentiles no suponen normalidad ni una forma concreta de la heterocedasticidad (Efron y Tibshirani 1993; Cameron y Miller 2015).

Los resultados son estables. En todas las especificaciones los coeficientes conservan el signo y un orden de magnitud similar; por ejemplo, el del título universitario (en el Sur) varía entre $[-1,283; -1,015]$, el de la cobertura sólo pública entre $[0,777; 0,935]$ y el de la incidencia entre $[0,175; 0,188]$. Las mayores diferencias aparecen con los efectos fijos de estado y el modelo mixto en la edad mediana y el tamaño del hogar: parte de su asociación con la mortalidad se produce entre estados, no dentro de ellos. El bootstrap por conglomerados da intervalos muy parecidos a los paramétricos (por ejemplo, $[-1,632; -0,615]$ para el título universitario frente a $[-1,566; -0,542]$), lo que confirma que la falta de normalidad de los residuos no afecta a la inferencia.

Tabla 8.1: Análisis de sensibilidad: coeficientes de las seis explicativas con mayor $|t|$ bajo especificaciones alternativas

Especificación	n	<i>Incidencia de cáncer</i>	<i>Edad mediana</i>	<i>Solo seguro público</i>	<i>Grado universitario (25+)</i>	<i>Tamaño medio del hogar</i>	<i>Bachillerato (18-24)</i>
MCO con errores típicos clásicos (salida tipo SPSS)	2840	0,187	-0,788	0,892	-1,054	-12,875	0,241
MCO con errores típicos HC3	2840	0,187	-0,788	0,892	-1,054	-12,875	0,241
Principal: MCO + errores cluster por estado	2840	0,187	-0,788	0,892	-1,054	-12,875	0,241
MCPF con $\sigma^2(n) = a + b/n$ y errores cluster	2840	0,178	-0,929	0,812	-1,134	-16,176	0,271
Modelo máximo: todas las candidatas tras la poda	2699	0,182	-0,616	0,935	-1,121	-12,545	0,226
Efectos fijos de estado (MCO + cluster)	2840	0,188	-0,581	0,915	-1,015	-10,647	0,154
Modelo mixto (intercepto aleatorio por estado)	2840	0,188	-0,595	0,856	-1,118	-10,680	0,163
Regresión robusta de Huber (M-estimador)	2840	0,188	-0,875	0,777	-1,192	-14,634	0,252
Sin los 185 condados influyentes (Cook > 4/n)	2655	0,175	-0,927	0,783	-1,283	-14,998	0,256
Imputación múltiple (20 conjuntos, todos los condados)	3047	0,188	-0,761	0,814	-1,090	-12,870	0,261
Bootstrap por conglomerados (999)	—	0,187	-0,784	0,893	-1,102	-12,456	0,234

†: no significativo al 5 % en esa especificación.




Figura 8.1: Coeficientes de las seis explicativas con mayor estadístico $|t|$ bajo cada especificación, con su intervalo de confianza al 95 %. La especificación principal está resaltada y el bootstrap por conglomerados aparece al final.

8.1 ¿Habría que transformar la respuesta?

El perfil de verosimilitud de Box-Cox condicionado a las explicativas del modelo final sitúa el parámetro en $\lambda = 0,725 [0,600; 0,850]$. El intervalo no contiene exactamente el 1, pero la transformación óptima es suave y la mejora en la forma de los residuos no compensa la pérdida de interpretabilidad: los coeficientes dejarían de estar en muertes por 100 000 habitantes. Con la inferencia robusta y el tamaño muestral disponibles, se mantiene la escala original, como pide la orientación.

Modelo predictivo

El modelo de efectos se construyó para interpretar. Si el objetivo es predecir la mortalidad de condados nuevos, el criterio cambia: lo que importa es el error fuera de la muestra, y pueden convenir modelos con más variables, regularizados o no lineales (Hastie et al. 2009). Este capítulo compara ocho modelos con un protocolo que evita estimaciones optimistas del error.

9.1 Protocolo

1. Se reserva una partición de prueba de 610 condados (20 %, estratificada por región) que no se usa para ajustar ni para elegir. Los 2437 restantes forman el entrenamiento.
2. En entrenamiento se comparan los modelos por validación cruzada de 10 pliegues. Los hiperparámetros (penalización de ridge, lasso y red elástica; profundidad y tasa de aprendizaje de los árboles) se eligen dentro de cada pliegue con una segunda validación cruzada (validación cruzada *anidada*), y la imputación de ausentes y la tipificación se ajustan también dentro del pliegue, para no filtrar información de la parte de validación.
3. Se repite con validación cruzada agrupada por estado: cada pliegue deja fuera estados completos. Mide la capacidad de predecir condados de estados no vistos; una partición aleatoria es optimista porque los condados de un mismo estado se parecen.
4. El modelo con menor RMSE en validación cruzada se evalúa una única vez en la prueba.

Los modelos comparados son: la media del entrenamiento (referencia), MCO con la especificación del modelo de efectos, MCO con todas las candidatas, ridge, lasso y red elástica (que pueden usar también indicadoras de estado), un bosque aleatorio y una potenciación del gradiente sobre histogramas.

9.2 Resultados

Tabla 9.1: Comparación de modelos predictivos: validación cruzada en entrenamiento y evaluación en prueba

Modelo	VC aleatoria (10)			VC estado	Prueba		
	RMSE	D. T.	R^2		RMSE	R^2	MAE
Referencia (media)	27,90	1,11	-0,003	27,93	27,10	-0,002	21,16
MCO con la especificación del modelo de efectos	19,11	1,44	0,527	19,43	18,18	0,549	13,85
MCO con todas las variables	18,61	1,37	0,551	20,36	17,44	0,585	13,26
Ridge*	18,59	1,37	0,553	19,68	17,36	0,589	13,18
Lasso	18,60	1,36	0,552	19,65	17,35	0,589	13,17
Red elástica	18,60	1,36	0,552	19,65	17,36	0,589	13,19
Bosque aleatorio	18,95	1,01	0,536	19,93	17,60	0,577	13,22
Potenciación del gradiente (histogramas)	19,03	0,90	0,532	19,81	17,61	0,577	13,36

*: modelo elegido por la regla configurada. La prueba se usa una sola vez, tras elegir.

El mejor modelo en validación cruzada es ridge (RMSE 18,59); lasso y red elástica quedan prácticamente empatados (18,60), y la regla de un error típico, que elegiría el modelo más sencillo cuyo




Figura 9.1: RMSE de cada modelo en validación cruzada aleatoria (media y desviación típica entre pliegues) y agrupada por estado.

error no supere al mínimo en más de una desviación típica, elegiría lasso. Los modelos de árboles no mejoran a los lineales regularizados: la relación es esencialmente lineal y aditiva, como sugería el diagnóstico. En la partición de prueba el modelo elegido obtiene un RMSE de 17,36 [16,25; 18,51] (intervalo bootstrap), $R^2 = 0,589$ y un error absoluto medio de 13,18; su ventaja sobre el MCO con la especificación de efectos es pequeña pero significativa (diferencia de RMSE $[-1,26; -0,40]$), atribuible a las covariables adicionales y, sobre todo, a las indicadoras de estado, que el modelo de efectos no usa. Ambos reducen en torno a un tercio el error de la predicción ingenua por la media (27,10).




Figura 9.2: Partición de prueba. Izquierda: mortalidad observada frente a la predicha por el modelo elegido, por región. Derecha: cobertura de los intervalos conformales estándar y normalizados según el tamaño del condado.

Dos matices sobre la honestidad de estas cifras. Primero, el RMSE de prueba es algo menor que el de validación cruzada por azar de la partición: el intervalo bootstrap lo cuantifica. Segundo, la especificación del modelo de efectos se seleccionó con todos los condados, de modo que su error en prueba es ligeramente optimista; el resto de modelos se ajustó sólo con el entrenamiento.

Cuando hay que predecir estados no vistos (validación agrupada), el error aumenta para todos los modelos y el mejor pasa a ser el MCO con la especificación del modelo de efectos (RMSE 19,43): las indicadoras de estado no sirven para estados nuevos, y un modelo parsimonioso generaliza mejor.

9.3 Importancia de las variables

La importancia por permutación mide cuánto empeora el RMSE en prueba al desordenar cada variable. Las tres más importantes para el modelo elegido son incidencia de cáncer, solo seguro público y hogares de matrimonios, en coherencia con el modelo de efectos.




Figura 9.3: Importancia por permutación en la partición de prueba (aumento medio del RMSE y su desviación típica en 15 permutaciones).

9.4 Intervalos de predicción conformales

Para acompañar cada predicción con un intervalo sin suponer normalidad se usó la predicción conformal (Lei et al. 2018): con los residuos fuera de pliegue del entrenamiento se calcula el cuantil que garantiza, para un condado nuevo intercambiable con los de entrenamiento, una cobertura de al menos el 90 %. El intervalo estándar tiene la misma anchura (60,0) para todos los condados y cubre el 91,1 % en prueba, pero de forma desigual: 81,9 % en los condados pequeños y 96,1 % en los grandes. El intervalo *normalizado* divide los residuos por $\hat{\sigma}(n)$, la desviación típica que da la función de varianza, y se ensancha donde la tasa es más ruidosa: cubre el 90,8 % globalmente, con una cobertura más equilibrada (88,2 % en los pequeños, 92,6 % en los grandes) y anchuras de 71,4 a 44,5 (tabla 9.2).

Tabla 9.2: Cobertura empírica en prueba de los intervalos de predicción conformales al 90 %

Condados	Estándar		Normalizado	
	Cobertura (%)	Anchura	Cobertura (%)	Anchura
Pequeños	81,9	60,0	88,2	71,4
Medianos	95,6	60,0	91,6	51,1
Grandes	96,1	60,0	92,6	44,5
Total	91,1	60,0	90,8	55,7

Conclusiones

10.1 Respuesta a la pregunta

En los condados de Estados Unidos, la mortalidad por cáncer se asocia, a igualdad del resto de características, con:

- la **incidencia**, que es el factor dominante: un condado en el tercer cuartil de incidencia tiene 12,4 muertes por 100 000 habitantes más que uno en el primero;
- la **cobertura sanitaria sólo pública**, indicador de pobreza y peor acceso a la atención especializada (7,4 muertes más entre el primer y el tercer cuartil);
- la **educación**: más adultos con título universitario, menos mortalidad ($-7,1$ muertes entre cuartiles en el Sur), con un gradiente mucho más débil en el Noreste; y más jóvenes cuyo nivel máximo es el bachillerato, más mortalidad;
- el **desempleo**, pero sólo en el Medio Oeste y el Noreste;
- la **región**: a igualdad de composición, el Sur conserva una mortalidad mayor que el Noreste y el Oeste, aunque el modelo explica el 56 % de la brecha bruta entre el Sur y el Oeste.

El modelo final, estimado por MCO con 2840 condados, explica el 55,8 % de la variabilidad ($\bar{R}^2 = 0,555$, RMSE = 18,44). Los errores son heterocedásticos y dependen dentro de cada estado; la inferencia lo tiene en cuenta mediante errores típicos robustos por conglomerados, y las conclusiones se mantienen en las 10 especificaciones del análisis de sensibilidad y en el bootstrap por conglomerados.

10.2 Limitaciones

- **Diseño ecológico y observacional**. Las asociaciones describen condados, no personas, y no son efectos causales: un condado con más titulados universitarios difiere en muchas otras cosas no medidas (tabaquismo, obesidad, exposición laboral, acceso a cribados).
- **Variables omitidas**. No se dispone de prevalencia de tabaquismo, el principal factor de riesgo evitable de muerte por cáncer, ni de la distribución por tipos de cáncer o por edad.
- **Ausencia estructural de la incidencia**. Los condados de los estados cuyos registros no publican la incidencia quedan fuera del modelo principal; la imputación múltiple muestra que las conclusiones no cambian, pero bajo el supuesto MAR.
- **Selección de variables**. Los errores típicos se calculan condicionados al modelo seleccionado; la reestimación del modelo máximo y la concordancia entre estrategias de selección limitan, pero no eliminan, este problema.

10.3 Trabajo futuro

Los datos admiten una estimación más eficiente si se modela directamente el número de muertes con un modelo de Poisson o binomial negativo con la población como exposición, lo que incorpora

de forma natural la heterocedasticidad debida al tamaño del condado; un modelo espacial permitiría además modelar la dependencia entre condados vecinos de estados distintos.

Código y reproducibilidad

Entregable (c): código

Todo el análisis está implementado en el paquete de Python `cancerstats`, con su configuración, pruebas automáticas e integración continua, en el repositorio del proyecto. Este apéndice describe cómo reproducirlo y reproduce la sintaxis de SPSS generada a partir de la corrida.

A.1 Estructura

`config/default.yaml`

Configuración de la metodología: cada umbral y cada decisión es una opción validada, con su descripción.

`src/cancerstats/`

Paquete: ingesta y procedencia (`io`, `provenance`), validación y depuración (`validation`, `cleaning`), ausentes (`missing`), exploración e inferencia clásica (`exploration`, `inference`), atípicos y colinealidad (`outliers`, `collinearity`), modelo de efectos (`effects/`: diseño, ajuste, selección, diagnóstico, interpretación y sensibilidad), modelo predictivo (`predictive`), registro de corridas (`runs`) y exportación (`export/`: macros y tablas del informe, figuras, sintaxis de SPSS y datos de la interfaz).

`runs/`

Una carpeta por corrida con la configuración, el manifiesto (entorno, huellas del código y de los datos, tiempos), los resultados, el registro y tablas en CSV.

`report/`

Este informe; `report/generado/` se regenera a partir de la última corrida.

`web/`

Interfaz interactiva (en vivo con el servidor de la API o estática en GitHub Pages).

`tests/`

Pruebas unitarias y de integración, que incluyen una reestimación independiente del modelo final con las fórmulas de `statsmodels`.

A.2 Cómo reproducir el análisis

Con `uv` instalado:

```
uv sync                # entorno exacto (uv.lock)
uv run cancerstats run  # ejecuta el pipeline y registra la corrida en runs/
uv run cancerstats export # regenera report/generado a partir de la última corrida
cd report && latexmk informe.tex
uv run cancerstats serve # interfaz interactiva en http://127.0.0.1:8000
```

La corrida de este informe es la 20261009-095405-f8341612, generada el 2026-10-09 09:56:44 UTC en 160 segundos a partir del commit aa76b3794edd con la configuración de huella f8341612ab08

y la semilla 20 261 007. Las bibliotecas principales son `statsmodels` (Seabold y Perktold 2010) para el modelo y el diagnóstico y `scikit-learn` (Pedregosa et al. 2011) para el modelo predictivo; la tabla A.1 recoge sus versiones.

Tabla A.1: Entorno de ejecución de la corrida del informe

Componente	Versión
python	3.12.3
numpy	2.5.3
pandas	3.0.6
scipy	1.18.1
statsmodels	0.15.0
scikit-learn	1.9.1
matplotlib	3.11.2
pydantic	2.13.5
Plataforma	Linux-6.18.44-fc-v80-x86_64-with-glibc2.39

A.3 Sintaxis de SPSS

La sintaxis siguiente, generada automáticamente a partir de la corrida, aplica sobre `practica.sav` las mismas decisiones de depuración, construye las mismas variables (región, transformaciones, centrado e interacciones) y estima el modelo final con el procedimiento `REGRESSION`, pidiendo los diagnósticos de la orientación: Durbin-Watson, gráficos de residuos, tolerancia y FIV, índices de condición y medidas de influencia. Sus coeficientes y errores típicos clásicos coinciden con los de la tabla 6.4.

Código A.1: Sintaxis de SPSS que reproduce el modelo final.

```
* =====.
* Reproducción en SPSS del modelo final MCO (proyecto cancer-stats).
* Generado automáticamente a partir de la corrida 20261009-095405-f8341612.
* Los coeficientes y errores típicos clásicos deben coincidir con la tabla
* «salida tipo SPSS» del informe. Ejecutar con el fichero oficial en la
* misma carpeta que esta sintaxis.
* =====.

SET DECIMAL=DOT.
GET FILE='../data/raw/practica.sav'.
DATASET NAME practica WINDOW=FRONT.

* D01: Geography separada en condado y estado (por la última coma).
STRING state (A40).
COMPUTE #coma = CHAR.RINDEX(Geography, ',').
COMPUTE state = LTRIM(CHAR.SUBSTR(Geography, #coma + 1)).
EXECUTE.

* D02: Notificadomuerte = avgAnnCount - avgDeathsPerYear (fuga): no entra en el modelo.

* D03: valor centinela de incidenceRate.
IF (ABS(incidenceRate - 453.5494221) < 0.0001) incidenceRate = $SYSMIS.

* D04: edad mediana registrada en meses.
IF (MedianAge > 100) MedianAge = RND(MedianAge / 12 * 10) / 10.
* D05: tamaño medio del hogar dividido por 100.
IF (AvgHouseholdSize < 1) AvgHouseholdSize = AvgHouseholdSize * 100.
* D06: PctSomeCol18_24 recuperada por identidad contable.
IF (MISSING(PctSomeCol18_24)) PctSomeCol18_24 = MAX(0, 100 - PctNoHS18_24 - PctHS18_24 -
PctBachDeg18_24).
* D07: población nativa o multirracial (residuo racial).
```

```

COMPUTE PctNativeMulti = MAX(0, 100 - (PctWhite + PctBlack + PctAsian + PctOtherRace)).
* D08: incidencia inverosímil (mortalidad mayor que incidencia).
IF (TARGET_deathRate / incidenceRate > 1) incidenceRate = $SYSMIS.
* D09: región censal.
STRING region (A12).
IF (ANY(RTRIM(state), 'Connecticut', 'Maine', 'Massachusetts', 'New Hampshire', 'Rhode Island',
  'Vermont', 'New Jersey', 'New York', 'Pennsylvania')) region = 'Noreste'.
IF (ANY(RTRIM(state), 'Illinois', 'Indiana', 'Michigan', 'Ohio', 'Wisconsin', 'Iowa', 'Kansas',
  'Minnesota', 'Missouri', 'Nebraska', 'North Dakota', 'South Dakota')) region = 'Medio
  Oeste'.
IF (ANY(RTRIM(state), 'Delaware', 'District of Columbia', 'Florida', 'Georgia', 'Maryland', '
  North Carolina', 'South Carolina', 'Virginia', 'West Virginia', 'Alabama', 'Kentucky', '
  Mississippi', 'Tennessee', 'Arkansas', 'Louisiana', 'Oklahoma', 'Texas')) region = 'Sur'.
IF (ANY(RTRIM(state), 'Arizona', 'Colorado', 'Idaho', 'Montana', 'Nevada', 'New Mexico', '
  Utah', 'Wyoming', 'Alaska', 'California', 'Hawaii', 'Oregon', 'Washington')) region = '
  Oeste'.
* D10: transformaciones.
COMPUTE logPop = LN(popEst2015).
COMPUTE logIncome = LN(medIncome).
COMPUTE logStudy = LN(1 + studyPerCap).
EXECUTE.

* Indicadoras de región (referencia: Sur).
COMPUTE reg_NE = (RTRIM(region) = 'Noreste').
COMPUTE reg_MO = (RTRIM(region) = 'Medio Oeste').
COMPUTE reg_OE = (RTRIM(region) = 'Oeste').

* Explicativas continuas centradas en la media de la muestra del modelo final.
COMPUTE c_incidenceRate = incidenceRate - 447.9725000000.
COMPUTE c_MedianAge = MedianAge - 40.7675700000.
COMPUTE c_AvgHouseholdSize = AvgHouseholdSize - 2.5373700000.
COMPUTE c_PctHS18_24 = PctHS18_24 - 35.2442300000.
COMPUTE c_PctBachDeg25_Over = PctBachDeg25_Over - 13.1516500000.
COMPUTE c_PctUnemployed16_Over = PctUnemployed16_Over - 8.0428870000.
COMPUTE c_PctPublicCoverageAlone = PctPublicCoverageAlone - 19.5347900000.
COMPUTE c_PctOtherRace = PctOtherRace - 1.9884140000.
COMPUTE c_BirthRate = BirthRate - 5.5805040000.
COMPUTE c_PctHS25_Over = PctHS25_Over - 34.9255300000.

* Interacciones (productos de variables centradas).
COMPUTE c_PctBachDeg25_Over_x_NE = c_PctBachDeg25_Over * reg_NE.
COMPUTE c_PctBachDeg25_Over_x_MO = c_PctBachDeg25_Over * reg_MO.
COMPUTE c_PctBachDeg25_Over_x_OE = c_PctBachDeg25_Over * reg_OE.
COMPUTE c_PctUnemployed16_Over_x_NE = c_PctUnemployed16_Over * reg_NE.
COMPUTE c_PctUnemployed16_Over_x_MO = c_PctUnemployed16_Over * reg_MO.
COMPUTE c_PctUnemployed16_Over_x_OE = c_PctUnemployed16_Over * reg_OE.
EXECUTE.

* Modelo final por mínimos cuadrados ordinarios, con los diagnósticos de la
* orientación: linealidad, independencia (Durbin-Watson), homocedasticidad,
* normalidad de los residuos, colinealidad (tolerancia, FIV e índices de condición)
* y casos atípicos e influyentes.
REGRESSION
  /MISSING LISTWISE
  /STATISTICS COEFF OUTS CI(95) R ANOVA COLLIN TOL
  /CRITERIA=PIN(.05) POUT(.10)
  /NOORIGIN
  /DEPENDENT TARGET_deathRate
  /METHOD=ENTER
  c_incidenceRate c_MedianAge c_AvgHouseholdSize c_PctHS18_24
  c_PctBachDeg25_Over c_PctUnemployed16_Over c_PctPublicCoverageAlone
  c_PctOtherRace c_BirthRate c_PctHS25_Over reg_NE reg_MO reg_OE
  c_PctBachDeg25_Over_x_NE c_PctBachDeg25_Over_x_MO

```

```

    c_PctBachDeg25_Over_x_OE c_PctUnemployed16_Over_x_NE
    c_PctUnemployed16_Over_x_MO c_PctUnemployed16_Over_x_OE
/SCATTERPLOT=(*ZRESID, *ZPRED) (*SRESID, *ZPRED)
/RESIDUALS DURBIN HISTOGRAM(ZRESID) NORMPROB(ZRESID)
/CASEWISE PLOT(ZRESID) OUTLIERS(3)
/SAVE PRED ZRESID SRESID COOK LEVER SDBETA.

* Contraste de Breusch-Pagan (versión de Koenker) a mano: regresión de los
* residuos al cuadrado sobre las explicativas; LM =  $n \cdot R^2$ .
COMPUTE res2 = (ZRE_1) ** 2.
REGRESSION /DEPENDENT res2 /METHOD=ENTER
    c_incidenceRate c_MedianAge c_AvgHouseholdSize c_PctHS18_24
    c_PctBachDeg25_Over c_PctUnemployed16_Over c_PctPublicCoverageAlone
    c_PctOtherRace c_BirthRate c_PctHS25_Over reg_NE reg_MO reg_OE
    c_PctBachDeg25_Over_x_NE c_PctBachDeg25_Over_x_MO
    c_PctBachDeg25_Over_x_OE c_PctUnemployed16_Over_x_NE
    c_PctUnemployed16_Over_x_MO c_PctUnemployed16_Over_x_OE.

```

Tablas complementarias

Tabla B.1: Diccionario de variables y papel de cada una en el análisis

Variable	Descripción	Unidad	Tipo	Fuente	Papel
TARGET_deathRate	Mortalidad por cáncer	muertes/100 000 hab.	cont.	(a)	respuesta
avgAnnCount	Casos anuales	casos/año	conteo	(a)	excluida
avgDeathsPerYear	Muertes anuales	muertes/año	conteo	(a)	excluida
incidenceRate	Incidencia de cáncer	casos/100 000 hab.	cont.	(a)	candidata
medIncome	Renta mediana	USD	cont.	(b)	candidata
popEst2015	Población	habitantes	conteo	(b)	candidata
povertyPercent	Pobreza	%	%	(b)	candidata
studyPerCap	Ensayos clínicos per cápita	ensayos/100 000 hab.	cont.	(a)	candidata
bracketedInc	Decil de renta	intervalo de USD	ord.	(b)	excluida
MedianAge	Edad mediana	años	cont.	(b)	candidata
MedianAgeMale	Edad mediana (hombres)	años	cont.	(b)	excluida
MedianAgeFemale	Edad mediana (mujeres)	años	cont.	(b)	excluida
AvgHouseholdSize	Tamaño medio del hogar	personas	cont.	(b)	candidata
PercentMarried	Población casada	%	%	(b)	candidata
PctNoHS18_24	Sin bachillerato (18–24)	%	%	(b)	candidata
PctHS18_24	Bachillerato (18–24)	%	%	(b)	candidata
PctSomeCol18_24	Estudios superiores incompletos (18–24)	%	%	(b)	excluida
PctBachDeg18_24	Grado universitario (18–24)	%	%	(b)	candidata
PctHS25_Over	Bachillerato (25+)	%	%	(b)	candidata
PctBachDeg25_Over	Grado universitario (25+)	%	%	(b)	candidata
PctEmployed16_Over	Empleo (16+)	%	%	(b)	candidata
PctUnemployed16_Over	Desempleo (16+)	%	%	(b)	candidata
PctPrivateCoverage	Seguro privado	%	%	(b)	candidata
PctPrivateCoverageAlone	Solo seguro privado	%	%	(b)	excluida
PctEmpPrivCoverage	Seguro privado vía empleador	%	%	(b)	candidata
PctPublicCoverage	Seguro público	%	%	(b)	candidata
PctPublicCoverageAlone	Solo seguro público	%	%	(b)	candidata
PctWhite	Población blanca	%	%	(b)	excluida
PctBlack	Población negra	%	%	(b)	candidata
PctAsian	Población asiática	%	%	(b)	candidata
PctOtherRace	Otra raza	%	%	(b)	candidata
PctMarriedHouseholds	Hogares de matrimonios	%	%	(b)	candidata
BirthRate	Natalidad	%	cont.	(b)	candidata
Geography	Condado	—	id.	(b)	excluida
state	Estado	—	cat.	(b)	excluida
Notificadomuerte	Casos menos muertes	casos/año	conteo	(derivada)	excluida
PctNativeMulti	Población nativa o multirracial	%	%	(derivada)	candidata

region	Región censal	—	cat.	(derivada)	factor
Fuente (a): registros de cáncer 2010–2016; (b): estimaciones censales de 2013; derivada: calculada en la depuración. Las variables excluidas y su motivo se detallan en la tabla B.2.					

Tabla B.2: Variables que no entran como explicativas y motivo

Variable	Motivo
avgDeathsPerYear	Fuga de información: es el numerador de la tasa de mortalidad que se quiere explicar.
avgAnnCount	Es un conteo que escala con la población (numerador de la incidencia) y falta, o es un valor centinela, en los condados de Kansas, Minnesota y Nevada.
Notificadomuerte	Fuga de información: es exactamente avgAnnCount – avgDeathsPerYear, de modo que contiene el numerador de la respuesta.
binnedInc	Es una función determinista de medIncome (su decil), información redundante.
Geography	Es un identificador, no una característica del condado.
state	Se usa como unidad de conglomerado; la región recoge el efecto geográfico.
MedianAgeMale	Redundante con MedianAge ($r > 0,9$); se usa sólo para validar y reparar.
MedianAgeFemale	Redundante con MedianAge ($r > 0,9$); se usa sólo para validar y reparar.
PctPrivateCoverageAlone	Combinación casi lineal de las demás coberturas ($R^2 \approx 0,99$) y 20 % de ausentes.
PctSomeCol18_24	Categoría de referencia de la composición educativa de 18–24 años: las cuatro suman 100 % e incluirlas todas haría singular X'X (como las tres indicadoras de una variable con tres categorías).
PctWhite	Categoría de referencia de la composición racial: blanca + negra + asiática + otra + nativa/multirracial = 100 %.

Tabla B.3: Correlación de cada candidata con la mortalidad

Variable	r	IC 95 % (Fisher)	ρ	p (Holm)
Grado universitario (25+)	-0,485	[-0,512; -0,458]	-0,502	< 0,001
Incidencia de cáncer	0,472	[0,443; 0,500]	0,428	< 0,001
log(Renta mediana)	-0,452	[-0,480; -0,424]	-0,463	< 0,001
Solo seguro público	0,449	[0,421; 0,477]	0,453	< 0,001
Pobreza	0,429	[0,400; 0,458]	0,443	< 0,001
Empleo (16+)	-0,412	[-0,442; -0,381]	-0,432	< 0,001
Bachillerato (25+)	0,405	[0,374; 0,434]	0,419	< 0,001
Seguro público	0,405	[0,374; 0,434]	0,401	< 0,001
Seguro privado	-0,386	[-0,416; -0,355]	-0,411	< 0,001
Desempleo (16+)	0,378	[0,348; 0,408]	0,403	< 0,001
Hogares de matrimonios	-0,293	[-0,325; -0,261]	-0,280	< 0,001
Grado universitario (18–24)	-0,288	[-0,320; -0,255]	-0,271	< 0,001
Seguro privado vía empleador	-0,267	[-0,300; -0,234]	-0,277	< 0,001
Población casada	-0,267	[-0,299; -0,234]	-0,259	< 0,001
Bachillerato (18–24)	0,262	[0,229; 0,295]	0,276	< 0,001
Población negra	0,257	[0,224; 0,290]	0,255	< 0,001
Otra raza	-0,190	[-0,224; -0,155]	-0,215	< 0,001
Población asiática	-0,186	[-0,220; -0,152]	-0,206	< 0,001
log(1 + ensayos per cápita)	-0,100	[-0,135; -0,064]	-0,113	< 0,001
Sin bachillerato (18–24)	0,088	[0,053; 0,124]	0,126	< 0,001
Natalidad	-0,087	[-0,123; -0,052]	-0,053	< 0,001
log(Población)	-0,071	[-0,106; -0,035]	-0,044	< 0,001
Población nativa o multirracial	0,043	[0,007; 0,078]	-0,139	0,054
Tamaño medio del hogar	-0,037	[-0,073; -0,002]	0,023	0,078
Edad mediana	-0,005	[-0,040; 0,031]	0,007	0,791

r : Pearson; ho : Spearman. Los p de Pearson se corrigen por comparaciones múltiples con el método de Holm.

Bibliografía

- Barnard, John y Donald B. Rubin (1999). «Small-Sample Degrees of Freedom with Multiple Imputation». En: *Biometrika* 86.4, págs. 948-955. doi: 10.1093/biomet/86.4.948.
- Belsley, David A., Edwin Kuh y Roy E. Welsch (1980). *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. Nueva York: Wiley. doi: 10.1002/0471725153.
- Box, George E. P. y David R. Cox (1964). «An Analysis of Transformations». En: *Journal of the Royal Statistical Society. Series B* 26.2, págs. 211-252. doi: 10.1111/j.2517-6161.1964.tb00553.x.
- Cameron, A. Colin y Douglas L. Miller (2015). «A Practitioner's Guide to Cluster-Robust Inference». En: *Journal of Human Resources* 50.2, págs. 317-372. doi: 10.3368/jhr.50.2.317.
- Cook, R. Dennis (1977). «Detection of Influential Observation in Linear Regression». En: *Technometrics* 19.1, págs. 15-18. doi: 10.1080/00401706.1977.10489493.
- Durbin, James y Geoffrey S. Watson (1950). «Testing for Serial Correlation in Least Squares Regression. I». En: *Biometrika* 37.3/4, págs. 409-428. doi: 10.2307/2332391.
- Efron, Bradley y Robert J. Tibshirani (1993). *An Introduction to the Bootstrap*. Nueva York: Chapman & Hall. doi: 10.1201/9780429246593.
- Fox, John (2016). *Applied Regression Analysis and Generalized Linear Models*. 3.^a ed. Thousand Oaks: SAGE.
- Hastie, Trevor, Robert Tibshirani y Jerome Friedman (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2.^a ed. Nueva York: Springer. doi: 10.1007/978-0-387-84858-7.
- Holm, Sture (1979). «A Simple Sequentially Rejective Multiple Test Procedure». En: *Scandinavian Journal of Statistics* 6.2, págs. 65-70.
- Huber, Peter J. (1964). «Robust Estimation of a Location Parameter». En: *The Annals of Mathematical Statistics* 35.1, págs. 73-101. doi: 10.1214/aoms/1177703732.
- Koenker, Roger (1981). «A Note on Studentizing a Test for Heteroscedasticity». En: *Journal of Econometrics* 17.1, págs. 107-112. doi: 10.1016/0304-4076(81)90062-2.
- Lei, Jing et al. (2018). «Distribution-Free Predictive Inference for Regression». En: *Journal of the American Statistical Association* 113.523, págs. 1094-1111. doi: 10.1080/01621459.2017.1307116.
- Little, Roderick J. A. (1988). «A Test of Missing Completely at Random for Multivariate Data with Missing Values». En: *Journal of the American Statistical Association* 83.404, págs. 1198-1202. doi: 10.1080/01621459.1988.10478722.
- MacKinnon, James G. y Halbert White (1985). «Some Heteroskedasticity-Consistent Covariance Matrix Estimators with Improved Finite Sample Properties». En: *Journal of Econometrics* 29.3, págs. 305-325. doi: 10.1016/0304-4076(85)90158-7.
- Maldonado, George y Sander Greenland (1993). «Simulation Study of Confounder-Selection Strategies». En: *American Journal of Epidemiology* 138.11, págs. 923-936. doi: 10.1093/oxfordjournals.aje.a116813.
- Pedregosa, Fabian et al. (2011). «Scikit-learn: Machine Learning in Python». En: *Journal of Machine Learning Research* 12, págs. 2825-2830.
- Ramsey, James B. (1969). «Tests for Specification Errors in Classical Linear Least-Squares Regression Analysis». En: *Journal of the Royal Statistical Society. Series B* 31.2, págs. 350-371. doi: 10.1111/j.2517-6161.1969.tb00796.x.
- Rippner, Noah (2017). *OLS Regression Challenge: Cancer Mortality in US Counties*. data.world. Datos agregados de la American Community Survey (census.gov), clinicaltrials.gov y cancer.gov. URL: <https://data.world/nrippner/ols-regression-challenge>.
- Robinson, William S. (1950). «Ecological Correlations and the Behavior of Individuals». En: *American Sociological Review* 15.3, págs. 351-357. doi: 10.2307/2087176.

- Rousseeuw, Peter J. y Katrien Van Driessen (1999). «A Fast Algorithm for the Minimum Covariance Determinant Estimator». En: *Technometrics* 41.3, págs. 212-223. DOI: 10.1080/00401706.1999.10485670.
- Rubin, Donald B. (1987). *Multiple Imputation for Nonresponse in Surveys*. Nueva York: Wiley. DOI: 10.1002/9780470316696.
- Seabold, Skipper y Josef Perktold (2010). «statsmodels: Econometric and Statistical Modeling with Python». En: *Proceedings of the 9th Python in Science Conference*, págs. 92-96. DOI: 10.25080/Majora-92bf1922-011.
- Van Buuren, Stef y Karin Groothuis-Oudshoorn (2011). «mice: Multivariate Imputation by Chained Equations in R». En: *Journal of Statistical Software* 45.3, págs. 1-67. DOI: 10.18637/jss.v045.i03.
- Wasserman, Larry (2004). *All of Statistics: A Concise Course in Statistical Inference*. Springer Texts in Statistics. Nueva York: Springer. DOI: 10.1007/978-0-387-21736-9.
- White, Halbert (1980). «A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity». En: *Econometrica* 48.4, págs. 817-838. DOI: 10.2307/1912934.
- Wooldridge, Jeffrey M. (2010). *Econometric Analysis of Cross Section and Panel Data*. 2.^a ed. Cambridge: MIT Press.